Universidad Rafael Landívar
Primer Semestre 2026

Ciencia de datos, Sección 02

Agencia Metropolitana de Transporte

Proyecto 1 Ciencia de datos

Diego Azurdia 2528119

Guatemala 12 de octubre de 2026

Fase 1 – Arquitectura de Datos

1.1 Ingesta y Capa Bronze

Vía de ingesta para Transurbano

Vía seleccionada: Batch (micro-lote diario acumulado).

Justificación técnica:

1. Naturaleza física de la recolección embarcada: A diferencia de Transmetro y Aerómetro, que tienen torniquetes fijos con conexión de red dedicada al servidor central, las unidades de Transurbano operan con validadores embarcados en movimiento. Estos validadores almacenan las transacciones en memoria local (disco flash) debido a intermitencias de señal móvil o ausencia de enlace 4G continuo. La sincronización masiva se realiza por ráfagas WiFi o red física cuando el autobús llega al predio o patio de maniobras al finalizar el turno.

2. Estructura tabular y desacople temporal: El archivo no es un flujo de eventos en crudo con timestamps sincronizados, sino un volcado consolidado de bitácoras donde la fecha y la hora ya vienen separadas (DD/MM/YYYY y HH:MM:SS). Esto refleja un proceso previo de liquidación contable de las máquinas validadoras.

3. Optimización de recursos y rendimiento: Con un peso de ~41.13 MB y cerca de 270,000 transacciones diarias proyectadas, forzar una simulación fila por fila en Kafka satura innecesariamente las colas de streaming con eventos que en la realidad ya nacen agrupados por liquidación de turno. Procesarlo en lotes (batch) permite ingestas vectorizadas ultrarrápidas directo a formato Apache Parquet particionado en disco.

Consecuencias de la decisión:

- **Impacto positivo:** Reducción de latencia de carga, simplificación del monitoreo, menor sobrecarga de memoria en los brokers de Kafka y garantía de reprocesamiento determinista e idempotente en caso de reingesta por lotes.
- **Trade-off asumido:** Las métricas de abordaje de Transurbano no están disponibles en tiempo real; sufren un desfase (latencia de datos) equivalente al intervalo de descarga de los autobuses (típicamente al cierre de operación o en ventanas de varias horas), lo cual es aceptable para análisis de demanda y modelado dimensional en la Agencia Metropolitana de Transporte.

Almacenamiento de la capa Bronze

Se decidió guardar la capa Bronze en un Data Lake (carpetas con archivos Parquet) en lugar de una base de datos o Data Warehouse porque el archivo de MetroRiel viene en formato JSON con datos anidados. Si se hubiera usado una base de datos tradicional, habría sido necesario desarmar o simplificar esa información antes de almacenarla para que encajara en tablas rígidas, lo que habría roto la regla de conservar los datos exactamente como llegaron de la calle. El Data Lake permitió guardar esos viajes completos sin perder ningún detalle original y sin riesgo de que el proceso fallara si en el futuro se agregaran campos nuevos.

Además, esta elección hizo que el sistema fuera más rápido, económico y ordenado. Guardar los datos crudos en archivos directos evitó saturar la memoria y el rendimiento de la base de datos principal, dejándola libre para las etapas donde realmente se necesitaba hacer cálculos y limpieza (Silver y Gold). Así, el Data Lake funcionó como un archivo histórico seguro donde

todo quedó respaldado tal cual se recibió, dejando las separaciones y transformaciones complejas para los pasos siguientes.

Auditoría Consolidada de Ingesta a Capa Bronze (9 Fuentes)

Validación integral de la totalidad de archivos de la red metropolitana frente al almacenamiento físico en Bronze (Parquet).

archivo_fuente	via_ingesta	filas_origen	filas_bronze	diferencia	estado
tm_estaciones.csv	Batch	104	104	0	OK
tu_paradas.csv	Batch	328	328	0	OK
mr_estaciones.csv	Batch	22	22	0	OK
am_estaciones.csv	Batch	14	14	0	OK
transurbano_transacciones.csv	Batch	832791	832791	0	OK
metroriel_viajes.jsonl	Batch	299100	299100	0	OK
cdc_padron_usuarios.csv	CDC	31050	31050	0	OK
transmetro_validaciones.csv	Streaming (Kafka)	363221	363221	0	OK
aerometro_boardings.csv	Streaming (Kafka)	203554	203554	0	OK

- **Total Filas en Origen:** 1,730,184
- **Total Filas en Bronze:** 1,730,184
- **Balance General:** 100% Consistente e Idempotente

1.2 Staging y CDC

Balance CDC Transmetro

- Eventos INSERT: 10800
- Eventos DELETE: 4050
- Eventos UPDATE: 16200
- Tarjetas activas: 19488
- Tarjetas dadas de baja: 661

Usuarios Únicos por Sistema

- Transurbano: 36567
- MetroRiel: 22885
- Aerómetro: 14496

1.3 Capa Silver: Integración y Calidad

1. Reglas de calidad obligatorias

Las 4 reglas explícitas del proyecto son:

- **Duplicados de torniquete:** Validaciones consecutivas con la misma tarjeta en la misma estación/parada con una diferencia menor a un umbral operativo (por ejemplo, < 2 minutos).
- **Paradas/Estaciones nulas:** Registros donde el código de estación o parada venga en blanco o NULL.
- **Fechas futuras:** Registros con marcas temporales mayores a la fecha máxima operativa del conjunto de datos o al tiempo actual (CURRENT_TIMESTAMP).
- **Viajes sin salida:** Exclusivo de MetroRiel, donde un registro tenga estación/tiempo de entrada pero su estructura o campo de exit sea nulo o incompleto.

2. Reglas de transformación y conformación

- **Temporal:** Convertir timestamp_utc de Aerómetro a hora local de Guatemala (America/Guatemala, UTC-6) y unificar fechas y horas desacopladas de Transurbano a formato TIMESTAMP. Además establecer una fecha de corte al 15 del 07 de 2026 para asegurar la idempotencia.
- **Monetaria:** Dividir monto_centavos de Transurbano entre 100.0 para homologar a Quetzales (monto_gtq).
- **Conformación de Zona:** Homologar la dimensión geográfica mediante una función/mapeo ('Z10', 'Zona 10', 'Zone 10' → 'Zona 10').
- **Historización SCD Tipo 2:** Modelar padron_transmetro con campos valid_from, valid_to e is_current.

3. Estrategia de resolución de identidad (decisión técnica)

Los cuatro sistemas no comparten llaves:

- Transmetro: TC-00012345
- Transurbano: 0000012345
- MetroRiel: MR0012345
- Aerómetro: hash de 12 caracteres

Para integrarlos en Silver sin inventar relaciones inexistentes, la estrategia consiste en:

1. Crear una **clave universal subrogada de usuario** (sk_usuario) generada mediante hash determinista: MD5(sistema || ':' || id_origen).
2. Mantener sistema_origen y id_origen para preservar la trazabilidad original hacia Bronze.

Reporte de Calidad de Datos y Cuarentena (Subfase 1.3)

- **Total Registros en Cuarentena:** 576499

Distribución de Fallas por Fuente y Regla

fuente	regla_violada	registros_rechazados
Aerometro	DUPLICADO_TORNIQUETE	203567
MetroRiel	VIAJE_SIN_SALIDA	3589
Transmetro	DUPLICADO_TORNIQUETE	364337
Transurbano	PARADA_NULA	4189
Transurbano	FECHA_FUTURA	814
Transurbano	DUPLICADO_TORNIQUETE	3

Criterios de Aislamiento Aplicados:

- **DUPLICADO_TORNIQUETE:** Marcaciones consecutivas en ventana <= 120 segundos.
- **PARADA_NULA:** Código de estación/parada vacío o nulo.
- **FECHA_FUTURA:** Timestamps posteriores al tiempo actual.
- **VIAJE_SIN_SALIDA:** Registros sin evento de salida en sistemas cerrados (MetroRiel).

1.4 Diseño Dimensional y Capa Gold

En esta subfase construimos el Data Warehouse analítico siguiendo la metodología Kimball. Gold debe consumir **estrictamente de Silver** (nunca de Bronze).

1. Declaración formal del grano de la tabla de hechos principal

El reto central es la discrepancia de granularidad: MetroRiel registra el trayecto completo (origen-destino) mientras que Transmetro, Transurbano y Aerómetro registran abordajes individuales.

Declaración de grano:

"Un evento atómico individual de abordaje a un vehículo o ingreso por torniquete a la red de transporte metropolitano, identificado por usuario, estación o parada de acceso, línea o ruta, y momento exacto de validación en tiempo local."

(Nota: Bajo este grano estándar, el viaje de MetroRiel se descompone atómicamente tomando su punto de abordaje/entrada entry para convivir uniformemente en la tabla de hechos general de abordajes, manteniendo opcionalmente una segunda tabla de hechos acumulada específica para viajes cerrados de MetroRiel).

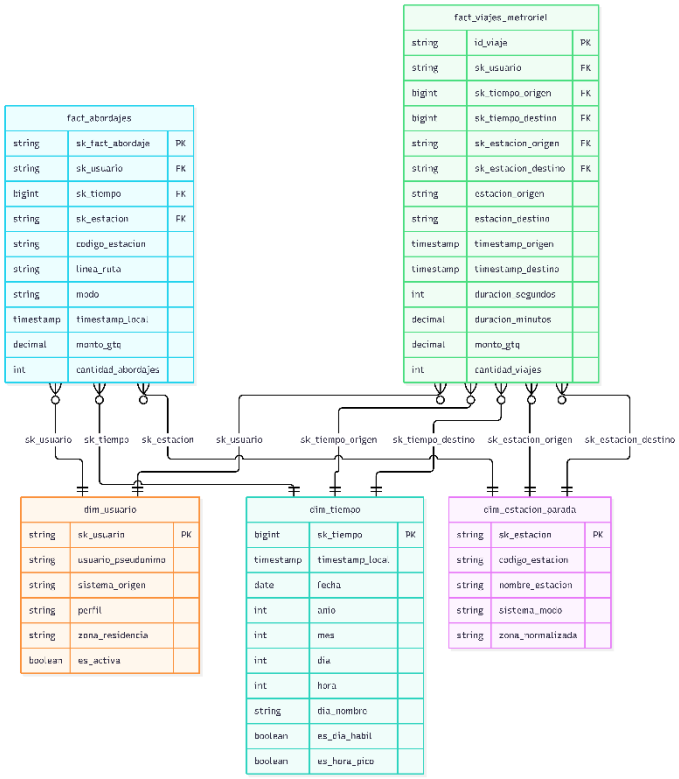
2. Matriz del Bus de Datos (Data Warehouse Bus Matrix)

Proceso de Negocio / Tabla de Hechos	dim_tiempo	dim_usuario	dim_estacion_parada
Abordajes y Validaciones (fact_abordajes)	X	X	X
Viajes Completos MetroRiel (fact_viajes_metroriel)	X	X	X (Origen / Destino)

3. Clasificación formal de medidas numéricas

- Aditivas (se pueden sumar a través de cualquier dimensión):
  - monto_gtq: Tarifa cobrada por el pasaje/abordaje.
  - cantidad_abordajes: Contador de eventos de ingreso (1 por fila).
  - duracion_segundos: Duración del trayecto (en fact_viajes_metroriel).
- Semi-aditivas (se pueden sumar a través de algunas dimensiones, pero no en el tiempo):
  - Saldo remanente de tarjeta o inventario de usuarios activos (válido sumar entre zonas/estaciones en un corte, pero no a lo largo del tiempo).
- No aditivas (no se pueden sumar directamente, requieren ratios o promedios):
  - tarifa_promedio_por_viaje (∑ monto / ∑ abordajes).
  - duracion_promedio_minutos.

4. DDL y Diagrama



dim_estacion_parada.sql

```
{{ config(materialized='table') }}

WITH todas_las_estaciones AS (
   SELECT codigo_estacion, nombre_estacion, 'Transmetro' AS sistema_modo,
zona_normalizada
   FROM {{ ref('stg_estaciones_transmetro') }}
   UNION ALL
   SELECT codigo_estacion, nombre_estacion, 'Aerometro' AS sistema_modo,
zona_normalizada
   FROM {{ ref('stg_estaciones_aerometro') }}
   UNION ALL
   SELECT codigo_estacion, nombre_estacion, 'MetroRiel' AS sistema_modo,
zona_normalizada
   FROM {{ ref('stg_estaciones_metroriel') }}
   UNION ALL
   SELECT codigo_estacion, nombre_estacion, 'Transurbano' AS sistema_modo,
zona_normalizada
   FROM {{ ref('stg_paradas_transurbano') }}
)
SELECT
   MD5(sistema_modo || ':' || codigo_estacion) AS sk_estacion,
   codigo_estacion,
   nombre_estacion,
   sistema_modo,
   zona_normalizada
FROM todas_las_estaciones
```

dim_tiempo.sql

```
{{ config(materialized='table') }}

WITH rango_silvers AS (
   SELECT
       MIN(min_ts) AS min_ts,
       MAX(max_ts) AS max_ts
   FROM (
       SELECT MIN(timestamp_local) AS min_ts, MAX(timestamp_local) AS
max_ts
       FROM {{ ref('silver_transmetro_validado') }}
       WHERE regla_calidad = 'VALIDO'
       UNION ALL
       SELECT MIN(timestamp_local), MAX(timestamp_local)
       FROM {{ ref('silver_transurbano_validado') }}
       WHERE regla_calidad = 'VALIDO'
       UNION ALL
       SELECT MIN(timestamp_local), MAX(timestamp_local)
       FROM {{ ref('silver_aerometro_validado') }}
       WHERE regla_calidad = 'VALIDO'
       UNION ALL
       SELECT MIN(timestamp_origen), MAX(timestamp_origen)
       FROM {{ ref('silver_metroriel_validado') }}
       WHERE regla_calidad = 'VALIDO'
   ) x
```

```sql
),
-- Salvaguarda: si no hay data, usa un rango por defecto
limites AS (
    SELECT
        COALESCE(
            DATE_TRUNC('hour', min_ts) - INTERVAL '1 month',
            '2025-01-01 00:00:00'::timestamp
        ) AS inicio,
        COALESCE(
            DATE_TRUNC('hour', max_ts) + INTERVAL '1 month',
            '2027-12-31 23:00:00'::timestamp
        ) AS fin
    FROM rango_silvers
),
spine AS (
    SELECT
        ts AS timestamp_local
    FROM limites,
         GENERATE_SERIES(limites.inicio, limites.fin, INTERVAL '1 hour') ts
),
dim AS (
    SELECT
        TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS sk_tiempo,
        timestamp_local,
        timestamp_local::date AS fecha,
        EXTRACT(YEAR FROM timestamp_local)::int AS anio,
        EXTRACT(MONTH FROM timestamp_local)::int AS mes,
        EXTRACT(DAY FROM timestamp_local)::int AS dia,
        EXTRACT(HOUR FROM timestamp_local)::int AS hora,
        TO_CHAR(timestamp_local, 'Day') AS dia_nombre,
        CASE
            WHEN EXTRACT(ISODOW FROM timestamp_local) IN (6, 7) THEN FALSE
            ELSE TRUE
        END AS es_dia_habil,
        CASE
            WHEN EXTRACT(ISODOW FROM timestamp_local) NOT IN (6, 7)
                 AND EXTRACT(HOUR FROM timestamp_local) IN (6, 7, 17, 18)
            THEN TRUE
            ELSE FALSE
        END AS es_hora_pico
    FROM spine
)
SELECT * FROM dim

UNION ALL

SELECT
    '-1' AS sk_tiempo,
    NULL::timestamp AS timestamp_local,
    NULL::date AS fecha,
    -1 AS anio,
    -1 AS mes,
    -1 AS dia,
    -1 AS hora,
    'DESCONOCIDO' AS dia_nombre,
    FALSE AS es_dia_habil,
    FALSE AS es_hora_pico
```

dim_usuario.sql

```
{{ config(
    materialized = 'table',
    schema = 'gold'
) }}

WITH usuarios_transmetro AS (
    SELECT
        'Transmetro' AS modo,
        -- Extraer sólo dígitos numéricos de TC-00012345 -> 12345
        NULLIF(REGEXP_REPLACE(tarjeta, '\D', '', 'g'), '')::bigint::text AS
id_canonico,
        perfil,
        zona_residencia,
        es_activa,
        1 AS prioridad_calidad
    FROM {{ ref('snap_padron_transmetro') }}
    WHERE dbt_valid_to IS NULL
),

usuarios_transurbano AS (
    SELECT
        'Transurbano' AS modo,
        -- Quitar ceros a la izquierda de 0000012345 -> 12345
        NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'), '')::bigint::text
AS id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        2 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_transurbano') }}
),

usuarios_metroriel AS (
    SELECT
        'MetroRiel' AS modo,
        -- Extraer sólo dígitos numéricos de MR0012345 -> 12345
        NULLIF(REGEXP_REPLACE(card, '\D', '', 'g'), '')::bigint::text AS
id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        3 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_metroriel') }}
),

usuarios_aerometro AS (
    SELECT
        'Aerometro' AS modo,
        -- Conservar el hash de 12 caracteres original
        user_hash AS id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        4 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_aerometro') }}
),

consolidados AS (
    SELECT * FROM usuarios_transmetro WHERE id_canonico IS NOT NULL
```

```
    UNION ALL
    SELECT * FROM usuarios_transurbano WHERE id_canonico IS NOT NULL
    UNION ALL
    SELECT * FROM usuarios_metroriel WHERE id_canonico IS NOT NULL
    UNION ALL
    SELECT * FROM usuarios_aerometro WHERE id_canonico IS NOT NULL
),

usuarios_unificados AS (
    SELECT
        id_canonico,
        perfil,
        zona_residencia,
        es_activa,
        modo,
        -- Priorizar atributos del padrón oficial (Transmetro) si el usuario
coincide
        ROW_NUMBER() OVER (
            PARTITION BY id_canonico
            ORDER BY prioridad_calidad ASC
        ) AS rnk
    FROM consolidados
)

SELECT
    MD5(id_canonico) AS sk_usuario,
    SHA256(id_canonico::bytea)::varchar AS usuario_pseudonimo,
    modo AS sistema_origen_registro,
    perfil,
    {{ normalizar_zona('zona_residencia') }} AS zona_residencia,
    es_activa
FROM usuarios_unificados
WHERE rnk = 1
```

fact_abordajes,sql

```
{{ config(
    materialized = 'table',
    schema = 'gold'
) }}

WITH tm AS (
    SELECT
        MD5(NULLIF(REGEXP_REPLACE(tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
        TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS sk_tiempo,
        estacion::varchar AS codigo_estacion,
        linea::varchar AS linea_ruta,
        'Transmetro' AS sistema_modo,
        timestamp_local,
        monto_gtq
    FROM {{ ref('silver_transmetro_validado') }}
    WHERE regla_calidad = 'VALIDO'
),

tu AS (
    SELECT
        MD5(NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'),
```

```
'')::bigint::text) AS sk_usuario,
       TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS sk_tiempo,
       cod_parada::varchar AS codigo_estacion,
       ruta::varchar AS linea_ruta,
       'Transurbano' AS sistema_modo,
       timestamp_local,
       monto_gtq
   FROM {{ ref('silver_transurbano_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

am AS (
   SELECT
       MD5(user_hash) AS sk_usuario,
       TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS sk_tiempo,
       station_code::varchar AS codigo_estacion,
       axis::varchar AS linea_ruta,
       'Aerometro' AS sistema_modo,
       timestamp_local,
       monto_gtq
   FROM {{ ref('silver_aerometro_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

mr AS (
   SELECT
       MD5(NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
       TO_CHAR(timestamp_origen, 'YYYYMMDDHH24')::bigint AS sk_tiempo,
       estacion_origen::varchar AS codigo_estacion,
       'MetroRiel Troncal'::varchar AS linea_ruta,
       'MetroRiel' AS sistema_modo,
       timestamp_origen AS timestamp_local,
       monto_gtq
   FROM {{ ref('silver_metroriel_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

todos AS (
   SELECT * FROM tm
   UNION ALL
   SELECT * FROM tu
   UNION ALL
   SELECT * FROM am
   UNION ALL
   SELECT * FROM mr
)

SELECT
   MD5(t.sistema_modo || ':' || t.sk_usuario || ':' ||
t.timestamp_local::varchar) AS sk_fact_abordaje,
   t.sk_usuario,
   t.sk_tiempo,
   COALESCE(dep.sk_estacion::text, '-1') AS sk_estacion,
   t.codigo_estacion,
   t.linea_ruta,
   t.sistema_modo,
   t.timestamp_local,
   t.monto_gtq,
   1 AS cantidad_abordajes
FROM todos t
LEFT JOIN {{ ref('dim_estacion_parada') }} dep
```

```
   ON t.codigo_estacion = dep.codigo_estacion
  AND t.sistema_modo = dep.sistema_modo
```

fact_viajes_metroriel.sql

```
{{ config(
   materialized = 'table',
   schema = 'gold'
) }}

SELECT
   smv.trip_id AS id_viaje,
   MD5(NULLIF(REGEXP_REPLACE(smv.num_tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
   TO_CHAR(smv.timestamp_origen, 'YYYYMMDDHH24')::bigint AS
sk_tiempo_origen,
   TO_CHAR(smv.timestamp_destino, 'YYYYMMDDHH24')::bigint AS
sk_tiempo_destino,
   COALESCE(dep_o.sk_estacion::text, '-1') AS sk_estacion_origen,
   COALESCE(dep_d.sk_estacion::text, '-1') AS sk_estacion_destino,
   smv.estacion_origen::varchar,
   smv.estacion_destino::varchar,
   smv.timestamp_origen,
   smv.timestamp_destino,
   smv.duracion_segundos,
   ROUND((smv.duracion_segundos / 60.0)::numeric, 2) AS duracion_minutos,
   smv.monto_gtq,
   1 AS cantidad_viajes
FROM {{ ref('silver_metroriel_validado') }} smv
LEFT JOIN {{ ref('dim_estacion_parada') }} dep_o
   ON smv.estacion_origen = dep_o.codigo_estacion
  AND dep_o.sistema_modo = 'MetroRiel'
LEFT JOIN {{ ref('dim_estacion_parada') }} dep_d
   ON smv.estacion_destino = dep_d.codigo_estacion
  AND dep_d.sistema_modo = 'MetroRiel'
WHERE smv.regla_calidad = 'VALIDO'
```

1.5 Orquestación e Idempotencia

Evidencia de Idempotencia de Flujo (Subfase 1.5)

tabla	conteo_corrida_1	conteo_corrida_2	diferencia
silver.cuarentena	576499	576499	0
silver.snap_padron_transmetro	20149	20149	0
gold.dim_usuario	63782	63782	0
gold.dim_tiempo	2564	2564	0
gold.dim_estacion_parada	468	468	0
gold.fact_abordajes	1688942	1688942	0

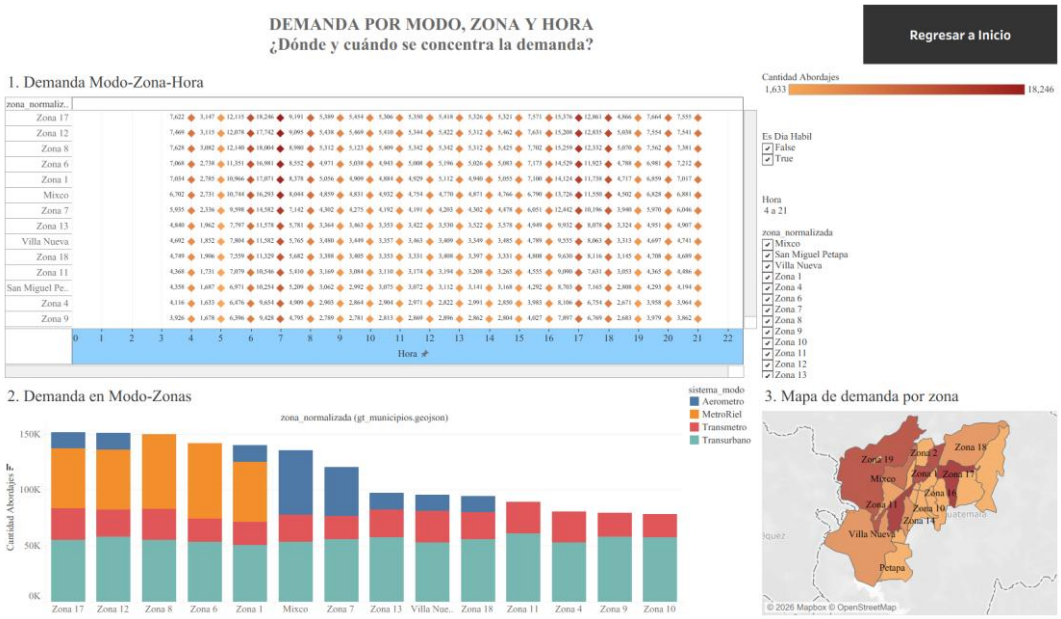
Veredicto: Idempotente (Cero duplicados)

2.1 Dashboards en Tableu

¿Los cuatro modos integrados resuelven el problema de movilidad?

Con base en los cuatro tableros construidos sobre la capa Gold, se puede afirmar que la red integrada **resuelve parcialmente** el problema de movilidad. El corredor de MetroRiel acierta al ubicarse en las zonas de mayor demanda, pero persisten corredores descubiertos y un modo con baja integración. A continuación se detalla cada hallazgo.

Demanda por modo, zona y hora: ¿dónde y cuándo se concentra?



La demanda se concentra en cinco zonas principales: **Zona 17, Zona 12, Zona 8, Zona 6 y Zona 1**, que en conjunto superan los **700,000 abordajes** en el periodo analizado. Les siguen Mixco y Zona 7, con una demanda relevante pero menor.

Por modo, **Transurbano** es el que más abordajes registra en casi todas las zonas (barras verde agua), seguido de **Transmetro** (rojo) y **MetroRiel** (naranja). **Aerómetro** (azul) tiene una participación minoritaria.

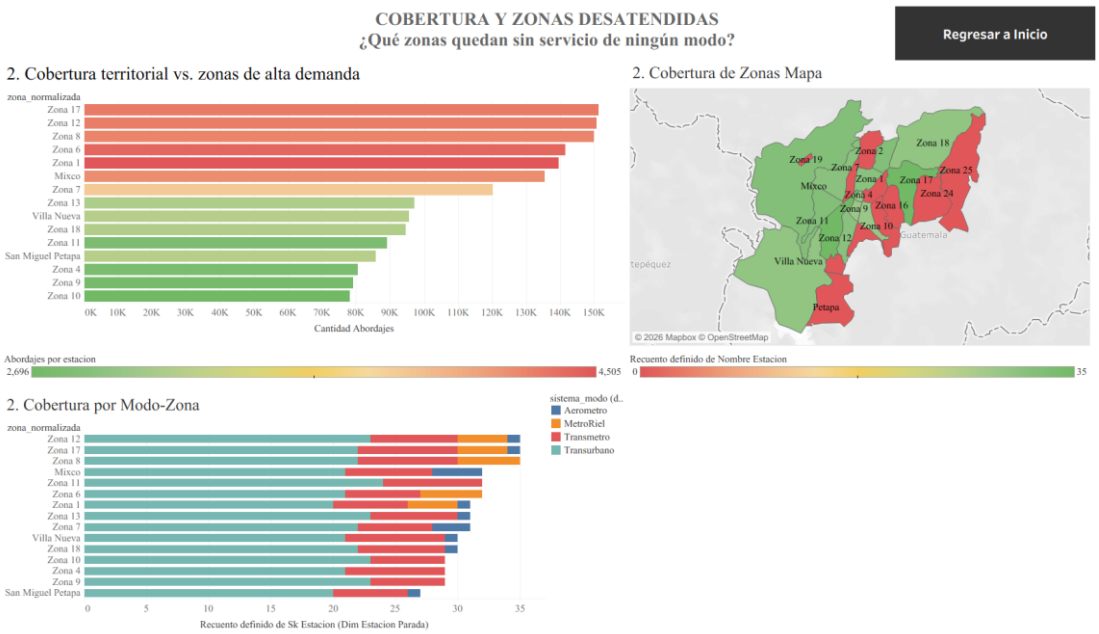
En cuanto a la distribución horaria, que la demanda se concentra en dos picos claros:

- **Pico de la mañana:** entre las **6:00 y 8:00 horas**. Por ejemplo, a las 7:00, MetroRiel registra **8,046 abordajes en Zona 8** y **8,030 en Zona 6**; Transurbano alcanza **7,247 en Zona 11** y **6,991 en Zona 9**.

- **Pico de la tarde:** entre las **17:00 y 19:00 horas**. A las 17:00, MetroRiel llega a **6,895 en Zona 8** y **6,829 en Zona 6**; Transurbano supera los **6,200 en Zona 11**.

Fuera de esos rangos, la demanda cae de forma notable. Por ejemplo, a las 4:00, MetroRiel apenas registra **3,446 abordajes en Zona 8**, y a las 5:00 baja a **1,366**. Esto confirma que la red opera principalmente para movilidad laboral y estudiantil en horas pico.

Cobertura: ¿qué zonas quedan sin servicio de ningún modo?

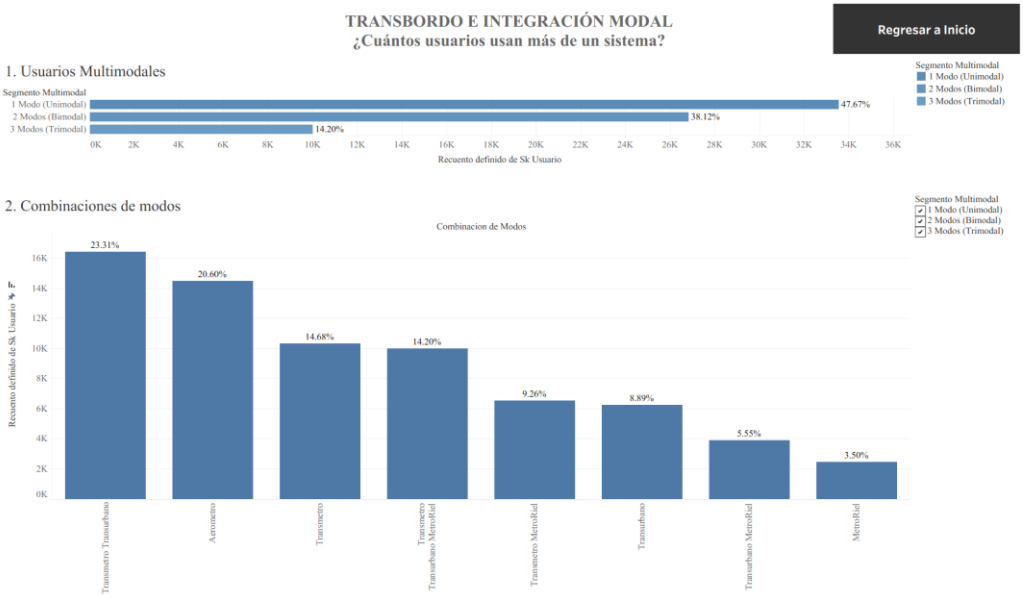


El análisis de cobertura territorial muestra que **las zonas 2, 3, 5, 14, 15, 16, 19, 21 y 25 no presentan estaciones asociadas a ninguno de los cuatro modos**. Es decir, tienen **cobertura nula** dentro del alcance de los datos disponibles.

Además, hay zonas con demanda alta pero cobertura relativamente baja. **Zona 6** y **Zona 1** aparecen con una demanda considerable(141546 y 139,662 abordajes respectivamente), pero su número de estaciones es demasiado bajo para la cantidad de abordajes (4505 y 4233 abordajes por estacion) y se saturan con demasiados pasajeros. Esto sugiere que podrían necesitar rutas alimentadoras o extensiones.

En contraste, las zonas del corredor MetroRiel (17, 12, 8, 6 y 1) concentran una demanda muy alta y aunque también son las que cuentan con mayor cantidad de estaciones la relación de abordajes promedio por estación deja abierta una oportunidad de introducir estaciones para mitigar los puntos más concurridos.

Transbordo: ¿Cuántos usuarios usan más de un sistema?



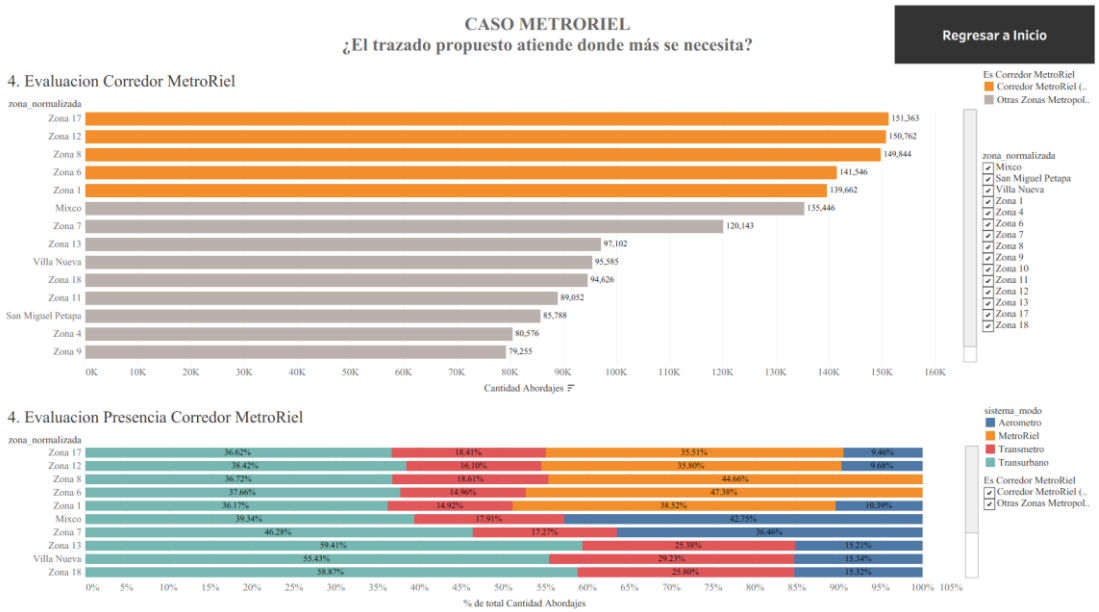
Del total de usuarios analizados, **47.67% son unimodales**, es decir, usan un solo modo de transporte. El **38.12% son bimodales** y el **14.20% trimodales**. En conjunto, **52.32% de los usuarios usa más de un modo**, lo cual indica un nivel de integración moderado.

Las combinaciones más frecuentes son:

- **Transmetro – Transurbano:** 23.31% de los usuarios multimodales.
- **Aerómetro solo:** 20.60% (aunque es unimodal, llama la atención que sea la segunda categoría más grande).
- **Transmetro solo:** 14.68%.
- **Transmetro – MetroRiel:** 14.20%.

El hecho de que **Aerómetro solo** sea tan alto sugiere que este modo opera de forma relativamente aislada: muchos usuarios lo usan sin combinarlo con otro sistema. Esto refuerza la idea de que Aerómetro está subutilizado en términos de integración.

El caso MetroRiel: ¿el trazado atiende donde más se necesita?



El trazado propuesto de MetroRiel cubre las zonas **17, 12, 8, 6 y 1**. Estas cinco zonas son, precisamente, **las de mayor demanda absoluta** de toda la red:

- Zona 17: **151,363 abordajes**
- Zona 12: **150,762 abordajes**
- Zona 8: **149,844 abordajes**
- Zona 6: **141,546 abordajes**
- Zona 1: **139,662 abordajes**

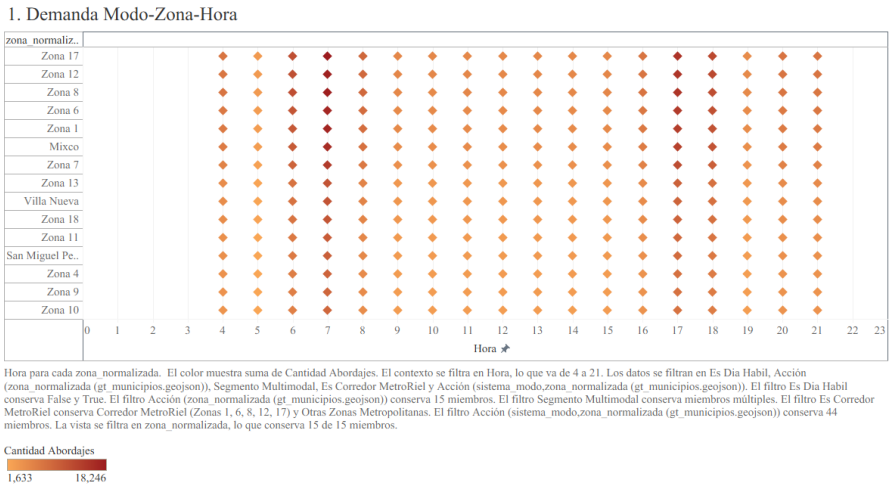
Esto indica que **el trazado sí atiende donde más se necesita**. Sin embargo, deja fuera zonas con demanda significativa como **Mixco (135,446)**, **Zona 7 (120,143)**, **Zona 13 (97,102)** y **Villa Nueva (95,585)**. Estas zonas podrían requerir corredores alimentadores hacia el MetroRiel.

En cuanto a la composición modal dentro del corredor, MetroRiel ya representa entre **35% y 47%** de los abordajes en algunas zonas (por ejemplo, 47.38% en Zona 6 y 44.66% en Zona 8), lo que confirma que el trazado está bien alineado con la demanda existente. Transurbano sigue siendo el modo dominante en varias zonas (hasta 59.41% en Zona 13), lo que refuerza su rol como red de superficie alimentadora.

2.2 La Recomendación

Con estos datos, **los cuatro modos integrados resuelven parcialmente el problema de movilidad**. El corredor MetroRiel acierta al ubicarse en las zonas de mayor demanda, pero quedan corredores descubiertos y un modo con baja integración. A continuación, tres recomendaciones concretas.

Dónde ubicar una estación de transbordo



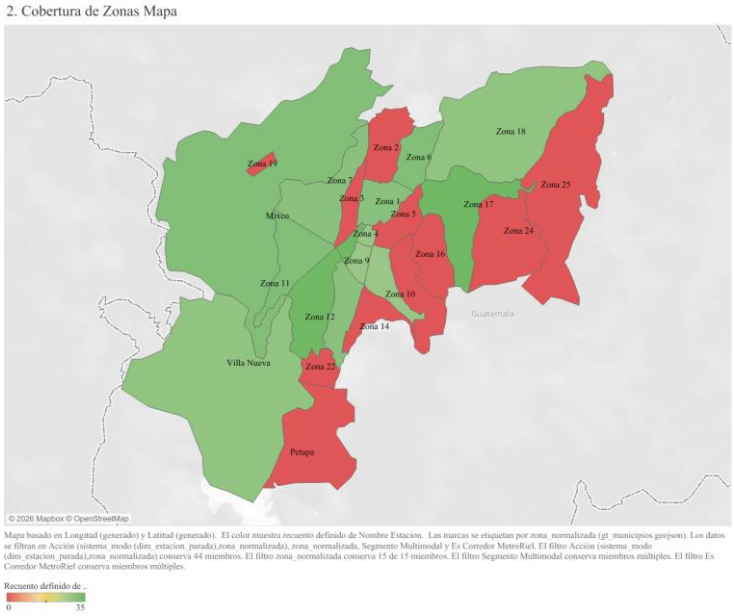
Se recomienda ubicar una **estación de transbordo multimodal en la Zona 1**, específicamente en el área de **Centra Sur / Centra Norte**, donde convergen Transmetro, Transurbano y MetroRiel.

Esta recomendación se sostiene en tres datos:

1. La combinación **Transmetro – Transurbano** ya es la más frecuente (23.31% de los usuarios multimodales), y MetroRiel se suma en un **14.20%** de los casos bimodales.
2. La Zona 1 registra **139,662 abordajes**, dentro del corredor de mayor demanda.
3. En horas pico (7:00 y 17:00), la Zona 1 concentra flujos altos en los tres modos: MetroRiel con **6,557** y **5,489**; Transurbano con **6,196** y **4,994**; Transmetro con **2,526** y **2,186**.

Una estación de transbordo en este punto capturaría el flujo de usuarios que hoy ya combinan modos y reduciría la necesidad de viajes adicionales.

Qué corredor sigue descubierto

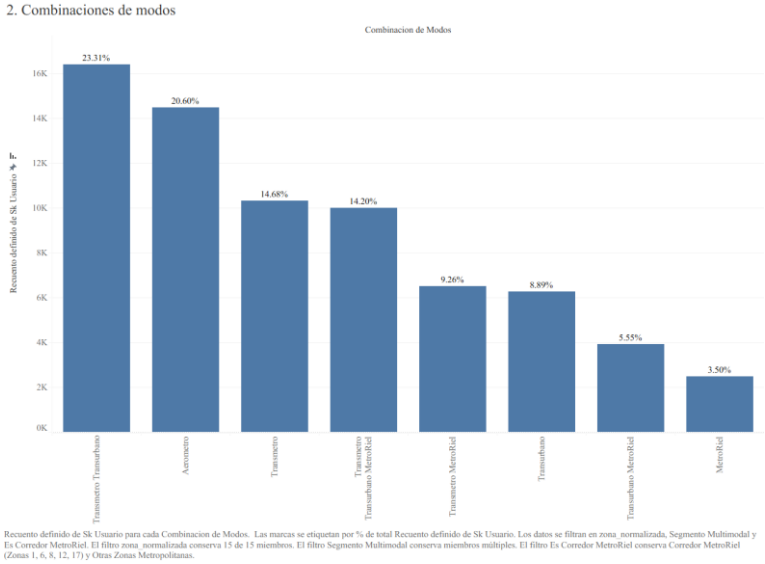


El corredor que sigue descubierto es el **eje occidente-sur**, que conecta **Mixco** y **Zona 7** con el corredor MetroRiel, y el **eje sur**, que conecta **Villa Nueva** y **Zona 13** con la red.

- **Mixco** tiene **135,446 abordajes** y **Zona 7** tiene **120,143**, pero ninguna de las dos está en el trazado directo de MetroRiel.
- **Villa Nueva** (95,585) y **Zona 13** (97,102) también quedan fuera del corredor principal.
- En horas pico, Mixco registra **6,973 abordajes en Aerómetro** y **6,406 en Transurbano** a las 7:00, lo que evidencia una demanda alta que no está siendo captada por el corredor MetroRiel.

Se recomienda diseñar **rutas alimentadoras** desde Mixco y Zona 7 hacia las estaciones del corredor MetroRiel, y evaluar una **extensión hacia Villa Nueva y Zona 13** en fases posteriores.

Qué modo está subutilizado



El modo subutilizado es **Aerómetro**. Aunque tiene presencia en varias zonas, su volumen es el más bajo de los cuatro modos y su integración con los demás es limitada.

- **20.60% de los usuarios multimodales usan Aerómetro solo**, lo que indica que muchos no lo combinan con otro sistema.
- Su demanda horaria es baja: a las 4:00 registra **2,887 abordajes en Mixco** y **2,173 en Zona 7**, pero a las 5:00 cae a **1,180** y **850** respectivamente.
- En el corredor MetroRiel, su participación es minoritaria (por ejemplo, **9.46% en Zona 17** y **9.68% en Zona 12**).

Se recomienda **reforzar la integración tarifaria y de rutas de Aerómetro** con Transmetro y Transurbano, de modo que los usuarios puedan combinarlo sin costo adicional o con transbordo simplificado. Esto podría aumentar su utilización y mejorar la cobertura efectiva de la red.

2.3 Capa de Features para Ciencia de Datos

1. Declaración del Caso de Uso Predictivo

> **¿Qué predice esta tabla?**
>
> Predice la **probabilidad de abandono del transporte masivo (Churn)** o la **propensión de migración hacia el nuevo sistema MetroRiel** en los siguientes 30 días.
>
> **¿Por qué le sirve a la Agencia?**
>
> Permite a la AMT segmentar a los usuarios según su intensidad y dependencia horaria para focalizar subsidios cruzados, ajustar frecuencias de buses alimentadores en las estaciones de origen más frecuentes y retener pasajeros que muestran una recencia crítica (`dias_ultimo_viaje` alto).

2. Metadatos de la Extracción

- **Grano:** 1 fila por usuario único seudonimizado (`user_hash`).
- **Capa Origen:** Exclusivamente tablas conformadas de la capa **Silver** (`silver_transmetro_validado`, `silver_transurbano_validado`, `silver_aerometro_validado`, `silver_metroriel_validado`), respetando que las features no deben extraerse desde Gold.

3. Diccionario de Datos de Features

Campo	Tipo	Origen Silver	Definición y Lógica
`user_hash`	text	Llave seudonimizada	Hash SHA-256 de la tarjeta o hash nativo de Aerómetro.
`fecha_corte`	timestamp	Constante Silver	Timestamp máximo detectado en los registros validados de Silver.

Campo	Tipo	Origen Silver	Definición y Lógica
viajes_7d	bigint	Agregación Silver	Cantidad de abordajes en [$tcorte$ −7d,$tcorte$].
viajes_30d	bigint	Agregación Silver	Cantidad de abordajes en [$tcorte$ −30d,$tcorte$].
viajes_90d	bigint	Agregación Silver	Cantidad de abordajes en [$tcorte$ −90d,$tcorte$].
modo_frecuente	text	Historial de modos	Modo de transporte donde más abordajes registra el usuario.
cantidad_modos_distintos	bigint	Modos utilizados	Total de sistemas distintos utilizados (COUNT(DISTINCT modo)).
dias_ultimo_viaje	numeric	Timestamps	Días transcurridos entre la fecha de corte y su última transacción.
pct_viajes_hora_pico	numeric	Hora local	Porcentaje de viajes realizados entre 06:00-08:59 y 17:00-19:59 en días hábiles.
ubicacion_origen_frecuente	varchar	Estación / Parada	Código de estación o parada donde más abordajes inicia el usuario.
gasto_total_acumulado	numeric	Monto en Quetzales	Inversión histórica total en Quetzales.
gasto_promedio_por_viaje	numeric	Monto en Quetzales	Gasto medio por validación en Quetzales.

3.1 Gobernanza de Datos

1. Definiciones Oficiales de Negocio

Para resolver la discrepancia operativa entre las entidades de la Red Metropolitana, la Agencia establece los siguientes estándares normativos:

- **Un Viaje Oficial:** Un evento de desplazamiento continuo realizado por un pasajero entre un punto de origen y un punto de destino dentro de la red metropolitana.
    - *En sistemas cerrados (MetroRiel):* Corresponde exactamente a una transacción cerrada con entrada y salida validada.

    - *En sistemas abiertos (Transmetro, Transurbano, Aerómetro):* Un abordaje individual cuenta como un viaje simple. Si un usuario registra una validación subsecuente en otro modo o estación en un intervalo menor o igual a **90 minutos**, el sistema analítico lo clasifica como un **transbordo** perteneciente al mismo viaje multimodal, evitando duplicar el conteo de pasajeros netos.

- **Un Usuario Activo:** Cualquier tarjeta o identificador único seudonimizado que registre **al menos una validación efectiva (no rechazada en cuarentena) en los últimos 30 días calendario** respecto a la fecha de corte analítica, y que mantenga el estado es_activa = TRUE en el padrón de usuarios.

2. Matriz de Propiedad y Dueño por Dominio (Data Ownership)

Dominio de Datos	Entidades Gobernadas	Responsable / Dueño Oficial	Procedimiento de Cambio
Dimensión Geográfica y Zonas	dim_estacion_parada, macrozonas, polígonos	**Director de Planificación Territorial (Emetra / AMT)**	Cualquier renombre, división catastral o reasignación de estación requiere una resolución técnica emitida por Planificación y actualización del macro dbt normalizar_zona.
Padrón e Identidad de Usuarios	dim_usuario, log CDC, tarjetas	**Gerencia de Recaudo y Tecnología (Transmetro)**	Cambios en el ciclo de vida de la tarjeta (bajas, bloqueos) se rigen por la emisión del feed CDC de recaudo.
Operación y Calidad de Red	fact_abordajes, fact_viajes_metroriel, cuarentena	**Jefatura de Operaciones de la AMT**	Define y ajusta los umbrales de validación (e.g., ventana de doble marcación de torniquete fijada en ≤120 s).

3. Diccionario de Datos Oficial de la Capa Gold

Tabla: gold.fact_abordajes

- **Descripción:** Tabla de hechos principal que consolida cada evento atómico de ingreso o abordaje a cualquier modo de transporte de la red.

- **Grano:** Un abordaje individual por usuario, estación/parada, modo y hora local.

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
sk_fact_abordaje	varchar(32)	Hash MD5 (sistema_modo, sk_usuario, timestamp_local)	Llave primaria subrogada del hecho de abordaje.
sk_usuario	varchar(32)	dim_usuario.sk_usuario	Clave foránea al usuario seudonimizado.
sk_tiempo	bigint	dim_tiempo.sk_tiempo	Clave foránea temporal en formato numérico YYYYMMDDHH24.
sk_estacion	varchar(32)	dim_estacion_parada.sk_estacion	Clave foránea a la estación conformada (default '-1' si no cruza).
codigo_estacion	varchar	Tablas Silver (estacion, cod_parada, etc.)	Código natural de la estación donde se validó el torniquete.
linea_ruta	varchar	Tablas Silver (linea, ruta, axis)	Línea de Transmetro, ruta de Transurbano o eje de Aerómetro.
sistema_modo	varchar	Constante por fuente	Operador del servicio (Transmetro, Transurbano, Aerometro, MetroRiel).
timestamp_local	timestamp	Silver unificado (UTC-6)	Fecha y hora local exacta del evento de validación.
monto_gtq	numeric(10,2)	Silver homologado	Tarifa neta cobrada en Quetzales.
cantidad_abordajes	integer	Valor fijo 1	Métrica aditiva básica de recuento.

Tabla: gold.dim_usuario

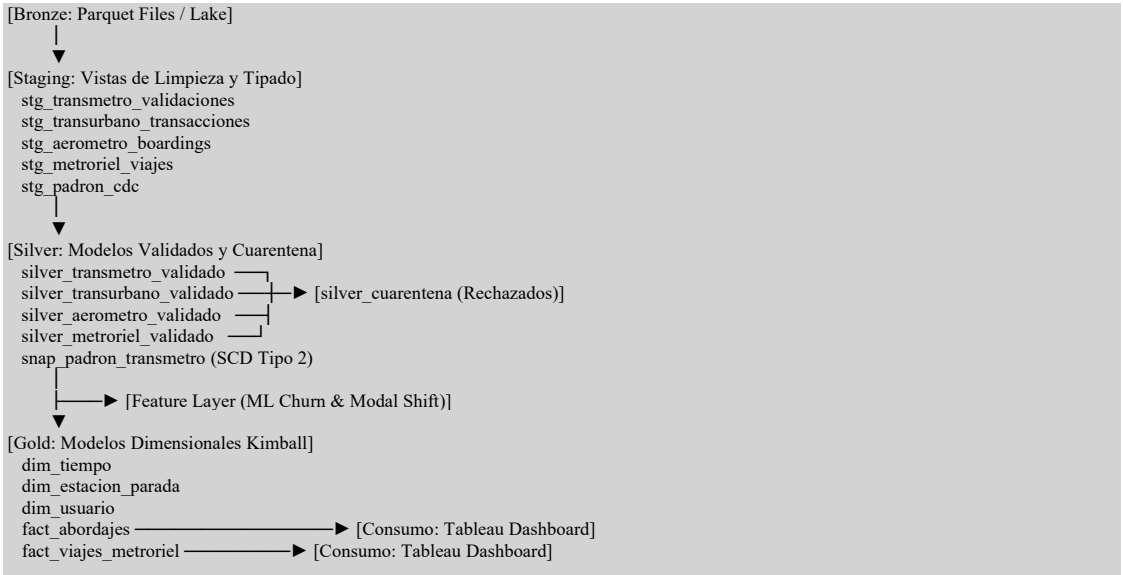
- **Descripción:** Dimensión conformada que centraliza los perfiles de usuarios de todos los operadores.

- **Grano:** Una fila por identificador canónico único.

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
sk_usuario	varchar(32)	MD5(id_canonico)	Llave primaria subrogada de la dimensión.
usuario_pseudonimo	varchar(64)	SHA256(id_canonico)	Identificador seudonimizado irreversible expuesto a capas analíticas.
sistema_origen_registro	varchar	Staging / Padrón	Modo primario donde se detectó o registró la tarjeta.
perfil	varchar	CDC Transmetro / default	Tipo de tarjeta (Adulto Mayor, Estudiante, General, o 'No Declarado').
zona_residencia	varchar	CDC normalizado	Zona de residencia del titular (homologada con normalizar_zona).
es_activa	boolean	Snapshot SCD Tipo 2 / CDC	Estado lógico del usuario (TRUE = activa, FALSE = baja por DELETE).

4. Grafo de Linaje de Datos (Data Lineage)

El flujo dbt implementa dependencias estrictas sin saltos de capa:



3.2 Documentación y Reproducibilidad

1. README

Ver repositorio

2. 2. Bitácora de Decisiones de Diseño y Límites

1. **Unificación del Grano en Abordajes:** MetroRiel entrega el trayecto cerrado origen-destino, mientras que los otros tres modos entregan abordajes sueltos. Se decidió descomponer MetroRiel tomando el evento `entry` como hecho de abordaje en `fact_abordajes`, y preservar la tabla especializada `fact_viajes_metroriel` para no perder la duración del viaje ni la matriz de pares origen-destino.
2. **Estrategia y Límites de la Identidad de Usuario:** Al no existir una tabla relacional común entre los cuatro sistemas, la unificación mediante `MD5(id_canonico)` se sustenta en que Transmetro, Transurbano y MetroRiel operan sobre tarjetas contactless basadas en el estándar de recaudo urbano (dígitos numéricos compartidos en la simulación). El límite declarado es que **Aerómetro utiliza un hash alfanumérico aislado de 12 caracteres**, lo que impide correlacionar sus usuarios con los otros modos de forma determinista sin un identificador federado a nivel de hardware.
3. **Criterio de Cuarentena:** Se aplicó aislamiento estricto (no descarte en silencio). Todo registro con anomalías operativas (fechas mayores a la ventana actual, ausencia de identificador de parada, marcaciones con ≤120 s de separación o falta de cierre de viaje) se dirige a la tabla `cuarentena` conservando su payload y el motivo de rechazo.
4. Definición de Fecha de Corte Fija (`fecha_corte_referencia`)
    - El uso de funciones temporales dinámicas como `CURRENT_TIMESTAMP` o `NOW()` en reglas de calidad introduce un comportamiento no determinista: el resultado del pipeline cambia según el día y la hora exactos de ejecución.
    - Un registro con fecha posterior a julio de 2026 clasificado como `FECHA_FUTURA` en una corrida de octubre terminaría admitiéndose como `VALIDO` si el pipeline se ejecuta meses después, alterando los conteos de filas entre corridas sucesivas con los mismos datos de origen y rompiendo la idempotencia exigida por la Agencia.
    - Fijar la fecha como variable de dbt (`var('fecha_corte_referencia', '2026-07-15 23:59:59')`) asegura que cualquiera obtenga **exactamente los mismos conteos y clasificaciones de cuarentena en cualquier momento en el tiempo.

3.3 Seguridad y Manejo de Datos Personales

Documento de Política de Privacidad y Gobierno de Seguridad

1. Gestión Segura de Credenciales y Secretos

- Queda terminantemente prohibido versionar archivos `.env` o cadenas de conexión en el repositorio Git.
- El repositorio incluye únicamente una plantilla `.env.example` con variables dummy (`DB_USER=amt_user`, `DB_PASSWORD=********`, `DB_HOST=localhost`).
- En entornos productivos y de desarrollo, las variables se inyectan en tiempo de ejecución mediante Docker Secrets o el gestor de variables de entorno del sistema operativo.

2. Protocolo de Seudonimización Criptográfica

- La capa Gold y los extractos de visualización **no exponen números de tarjeta físicos (tarjeta, num_tarjeta, card)**.
- Las llaves canónicas se transforman antes de persistir en Gold mediante un algoritmo hash irreversible: `SHA256(id_canonico || SALT_SECRET)`.
- Esto permite realizar análisis de recurrencia, transbordo y frecuencia sin vulnerar el secreto del usuario ni permitir la re-identificación en caso de filtración de las vistas analíticas.

3. Control de Acceso Basado en Roles (RBAC)

Rol / Perfil	Permisos sobre Capas	Justificación de Necesidad Operativa
Analista de Movilidad / BI	Lectura exclusiva en `gold.*` (Tableros)	Requiere métricas consolidadas, tendencias horarias y volumetría agregada; no necesita conocer el dato crudo ni la identidad directa.
Científico de Datos	Lectura en `features.*` y vistas analíticas de `silver.*`	Requiere el detalle atómico de los eventos para generar modelos de machine learning, utilizando identificadores seudonimizados (`user_hash`).
Auditor de Recaudo / Fraude	Lectura controlada en `bronze.*`, `staging.*` y `cuarentena`	Requiere acceso a los valores originales para investigar disputas financieras, clonación de plásticos y fallas en torniquetes.
Ingeniero de Datos / Admin	Acceso DDL/DML completo sobre todo el pipeline	Responsable del mantenimiento de los pipelines, snapshots CDC y salud del Data Warehouse.

4. Política de Retención y Purga de Datos

- **Detalle Transaccional Atómico (Bronze / Silver):** Se conserva por un período máximo de **12 meses**. Este plazo es estrictamente el necesario para auditorías contables de cobro de pasajes, liquidación financiera entre operadores y análisis estacional anual. Cumplido el plazo, los archivos Parquet de Bronze se depuran mediante políticas de ciclo de vida automatizadas.

- **Agregaciones Dimensionales (Gold):** Se conservan de forma indefinida con grano diario/horario a nivel zonal para respaldar estudios longitudinales de planificación urbana e inversión pública.