Universidad Rafael Landívar

Primer Semestre 2026

Ciencia de datos, Sección 02

Agencia Metropolitana de Transporte

Diego Azurdia 2528119

Guatemala, 12 de octubre de 2026

Repositorio: diegoazurdia1998/proyecto-red-metropolitana

Fase 1 – Arquitectura de Datos

1.1 Ingesta y Capa Bronze

Vía de ingesta para Transurbano

Vía seleccionada: Batch (micro-lote diario acumulado).

Justificación técnica:

1.Naturaleza física de la recolección embarcada: A diferencia de Transmetro y Aerómetro, que tienen torniquetes fijos con conexión de red dedicada al servidor central, las unidades de Transurbano operan con validadores embarcados en movimiento. Estos validadores almacenan las transacciones en memoria local (disco flash) debido a intermitencias de señal móvil o ausencia de enlace 4G continuo. La sincronización masiva se realiza por ráfagas WiFi o red física cuando el autobús llega al predio o patio de maniobras al finalizar el turno.

2.Estructura tabular y desacople temporal: El archivo no es un flujo de eventos en crudo con timestamps sincronizados, sino un volcado consolidado de bitácoras donde la fecha y la hora ya vienen separadas (DD/MM/YYYY y HH:MM:SS). Esto refleja un proceso previo de liquidación contable de las máquinas validadoras.

3.Optimización de recursos y rendimiento: Con un peso de ~41.13 MB y cerca de 270,000 transacciones diarias proyectadas, forzar una simulación fila por fila en Kafka satura innecesariamente las colas de streaming con eventos que en la realidad ya nacen agrupados por liquidación de turno. Procesarlo en lotes (batch) permite ingestas vectorizadas ultrarrápidas directo a formato Apache Parquet particionado en disco.

Consecuencias de la decisión:

- **Impacto positivo:** Reducción de latencia de carga, simplificación del monitoreo, menor sobrecarga de memoria en los brokers de Kafka y garantía de reprocesamiento determinista e idempotente en caso de reingesta por lotes.
- **Trade-off asumido:** Las métricas de abordaje de Transurbano no están disponibles en tiempo real; sufren un desfase (latencia de datos) equivalente al intervalo de descarga de los autobuses (típicamente al cierre de operación o en ventanas de varias horas), lo cual es aceptable para análisis de demanda y modelado dimensional en la Agencia Metropolitana de Transporte.

Almacenamiento de la capa Bronze

Se decidió guardar la capa Bronze en un Data Lake (carpetas con archivos Parquet) en lugar de una base de datos o Data Warehouse porque el archivo de MetroRiel viene en formato JSON con datos anidados. Si se hubiera usado una base de datos tradicional, habría sido

necesario desarmar o simplificar esa información antes de almacenarla para que encajara en tablas rígidas, lo que habría roto la regla de conservar los datos exactamente como llegaron de la calle. El Data Lake permitió guardar esos viajes completos sin perder ningún detalle original y sin riesgo de que el proceso fallara si en el futuro se agregaran campos nuevos.

Además, esta elección hizo que el sistema fuera más rápido, económico y ordenado. Guardar los datos crudos en archivos directos evitó saturar la memoria y el rendimiento de la base de datos principal, dejándola libre para las etapas donde realmente se necesitaba hacer cálculos y limpieza (Silver y Gold). Así, el Data Lake funcionó como un archivo histórico seguro donde todo quedó respaldado tal cual se recibió, dejando las separaciones y transformaciones complejas para los pasos siguientes.

Reporte de Ingesta Batch y CDC a Bronze

- **Destino:** Capa Bronze (Archivos Parquet comprimidos con SNAPPY)
- **Total Registros Procesados:** 1163409

Detalle de Registros por Archivo Fuente

archivo_fuente	registros_ingeridos
tm_estaciones.csv	104
tu_paradas.csv	328
mr_estaciones.csv	22
am_estaciones.csv	14
transurbano_transacciones.csv	832791
metroriel_viajes.jsonl	299100
cdc_padron_usuarios.csv	31050

Fuentes Ingeridas:

- **Catálogos:** Estaciones de Transmetro, paradas de Transurbano, estaciones de MetroRiel y Aerómetro.
- **Transacciones:** Transurbano (CSV) y MetroRiel (JSONL).
- **Log CDC:** Padrón histórico de usuarios de Transmetro.

1.2 Staging y CDC

Resumen CDC y Catálogos Mínimos

Balance CDC Transmetro

- **Eventos INSERT:** 10800
- **Eventos DELETE:** 4050
- **Eventos UPDATE:** 16200
- **Tarjetas activas:** 19488
- **Tarjetas dadas de baja:** 661

Usuarios Únicos por Sistema

- **Transurbano:** 36567
- **MetroRiel:** 22885
- **Aerómetro:** 14496

1.3 Capa Silver: Integración y Calidad

1. Reglas de calidad obligatorias

Las 4 reglas explícitas del proyecto son:

- **Duplicados de torniquete:** Validaciones consecutivas con la misma tarjeta en la misma estación/parada con una diferencia menor a un umbral operativo (por ejemplo, < 2 minutos).
- **Paradas/Estaciones nulas:** Registros donde el código de estación o parada venga en blanco o NULL.
- **Fechas futuras:** Registros con marcas temporales mayores a la fecha máxima operativa del conjunto de datos o al tiempo actual (CURRENT_TIMESTAMP).
- **Viajes sin salida:** Exclusivo de MetroRiel, donde un registro tenga estación/tiempo de entrada pero su estructura o campo de exit sea nulo o incompleto.

2. Reglas de transformación y conformación

- **Temporal:** Convertir timestamp_utc de Aerómetro a hora local de Guatemala (America/Guatemala, UTC-6) y unificar fechas y horas desacopladas de Transurbano a formato TIMESTAMP.
- **Monetaria:** Dividir monto_centavos de Transurbano entre 100.0 para homologar a Quetzales (monto_gtq).
- **Conformación de Zona:** Homologar la dimensión geográfica mediante una función/mapeo ('Z10', 'Zona 10', 'Zone 10' → 'Zona 10').
- **Historización SCD Tipo 2:** Modelar padron_transmetro con campos valid_from, valid_to e is_current.

3. Estrategia de resolución de identidad (decisión técnica)

Los cuatro sistemas no comparten llaves:

- Transmetro: TC-00012345
- Transurbano: 0000012345
- MetroRiel: MR0012345
- Aerómetro: hash de 12 caracteres

Para integrarlos en Silver sin inventar relaciones inexistentes, la estrategia consiste en:

1. Crear una **clave universal subrogada de usuario** (sk_usuario) generada mediante hash determinista: MD5(sistema || ':' || id_origen).
2. Mantener sistema_origen y id_origen para preservar la trazabilidad original hacia Bronze.

Reporte de Calidad de Datos y Cuarentena

- **Total Registros en Cuarentena:** 9724

Distribución de Fallas por Fuente y Regla

fuente	regla_violada	registros_rechazados
Aerometro	DUPLICADO_TORNIQUETE	13
MetroRiel	VIAJE_SIN_SALIDA	3589
Transmetro	DUPLICADO_TORNIQUETE	1116
Transurbano	PARADA_NULA	4189
Transurbano	FECHA_FUTURA	814
Transurbano	DUPLICADO_TORNIQUETE	3

Criterios de Aislamiento Aplicados:

- **DUPLICADO_TORNIQUETE:** Marcaciones consecutivas en ventana <= 120 segundos.
- **PARADA_NULA:** Código de estación/parada vacío o nulo.
- **FECHA_FUTURA:** Timestamps posteriores al tiempo actual.
- **VIAJE_SIN_SALIDA:** Registros sin evento de salida en sistemas cerrados (MetroRiel).

1.4 Diseño Dimensional y Capa Gold

En esta subfase construimos el Data Warehouse analítico siguiendo la metodología Kimball. Gold debe consumir **estrictamente de Silver** (nunca de Bronze).

1. Declaración formal del grano de la tabla de hechos principal

El reto central es la discrepancia de granularidad: MetroRiel registra el trayecto completo (origen-destino) mientras que Transmetro, Transurbano y Aerómetro registran abordajes individuales.

- **Declaración de grano:**

"Un evento atómico individual de abordaje a un vehículo o ingreso por torniquete a la red de transporte metropolitano, identificado por usuario, estación o parada de acceso, línea o ruta, y momento exacto de validación en tiempo local."

(Nota: Bajo este grano estándar, el viaje de MetroRiel se descompone atómicamente tomando su punto de abordaje/entrada entry para convivir uniformemente en la tabla de hechos general de abordajes, manteniendo opcionalmente una segunda tabla de hechos acumulada específica para viajes cerrados de MetroRiel).

2. Matriz del Bus de Datos (Data Warehouse Bus Matrix)

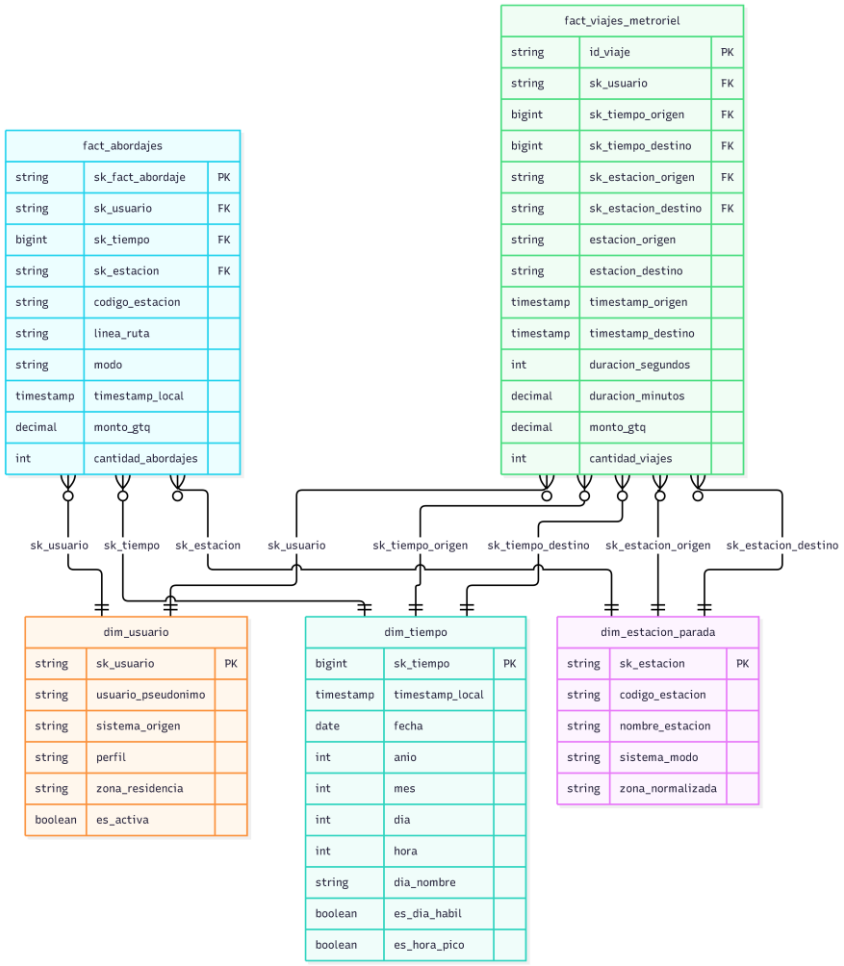
Proceso de Negocio / Tabla de Hechos	**dim_tiempo**	**dim_usuario**	**dim_estacion_parada**
Abordajes y Validaciones (fact_abordajes)	X	X	X
Viajes Completos MetroRiel (fact_viajes_metroriel)	X	X	X (Origen / Destino)

3. Clasificación formal de medidas numéricas

- Aditivas (se pueden sumar a través de cualquier dimensión):
  - monto_gtq: Tarifa cobrada por el pasaje/abordaje.
  - cantidad_abordajes: Contador de eventos de ingreso (1 por fila).
  - duracion_segundos: Duración del trayecto (en fact_viajes_metroriel).
- Semi-aditivas (se pueden sumar a través de algunas dimensiones, pero no en el tiempo):
  - Saldo remanente de tarjeta o inventario de usuarios activos (válido sumar entre zonas/estaciones en un corte, pero no a lo largo del tiempo).

- No aditivas (no se pueden sumar directamente, requieren ratios o promedios):
  - tarifa_promedio_por_viaje (∑ monto / ∑ abordajes).
  - duracion_promedio_minutos.

4. DDL y Diagrama



dim_estacion_parada.sql

```
{{ config(materialized='table') }}

WITH todas_las_estaciones AS (
   SELECT codigo_estacion, nombre_estacion, 'Transmetro' AS
sistema_modo, zona_normalizada
   FROM {{ ref('stg_estaciones_transmetro') }}
   UNION ALL
   SELECT codigo_estacion, nombre_estacion, 'Aerometro' AS
sistema_modo, zona_normalizada
   FROM {{ ref('stg_estaciones_aerometro') }}
   UNION ALL
   SELECT codigo_estacion, nombre_estacion, 'MetroRiel' AS
sistema_modo, zona_normalizada
```

```
    FROM {{ ref('stg_estaciones_metroriel') }}
    UNION ALL
    SELECT codigo_estacion, nombre_estacion, 'Transurbano' AS
sistema_modo, zona_normalizada
    FROM {{ ref('stg_paradas_transurbano') }}
)

SELECT
    MD5(sistema_modo || ':' || codigo_estacion) AS sk_estacion,
    codigo_estacion,
    nombre_estacion,
    sistema_modo,
    zona_normalizada
FROM todas_las_estaciones
```

dim_tiempo.sql

```
{{ config(materialized='table') }}

WITH rango_silvers AS (
    SELECT
        MIN(min_ts) AS min_ts,
        MAX(max_ts) AS max_ts
    FROM (
        SELECT MIN(timestamp_local) AS min_ts,
MAX(timestamp_local) AS max_ts
        FROM {{ ref('silver_transmetro_validado') }}
        WHERE regla_calidad = 'VALIDO'
        UNION ALL
        SELECT MIN(timestamp_local), MAX(timestamp_local)
        FROM {{ ref('silver_transurbano_validado') }}
        WHERE regla_calidad = 'VALIDO'
        UNION ALL
        SELECT MIN(timestamp_local), MAX(timestamp_local)
        FROM {{ ref('silver_aerometro_validado') }}
        WHERE regla_calidad = 'VALIDO'
        UNION ALL
        SELECT MIN(timestamp_origen), MAX(timestamp_origen)
        FROM {{ ref('silver_metroriel_validado') }}
        WHERE regla_calidad = 'VALIDO'
    ) x
),

-- Salvaguarda: si no hay data, usa un rango por defecto
limites AS (
    SELECT
        COALESCE(
            DATE_TRUNC('hour', min_ts) - INTERVAL '1 month',
            '2025-01-01 00:00:00'::timestamp
```

```
        ) AS inicio,
        COALESCE(
            DATE_TRUNC('hour', max_ts) + INTERVAL '1 month',
            '2027-12-31 23:00:00'::timestamp
        ) AS fin
    FROM rango_silvers
),

spine AS (
    SELECT
        ts AS timestamp_local
    FROM limites,
         GENERATE_SERIES(limites.inicio, limites.fin, INTERVAL '1
hour') ts
),

dim AS (
    SELECT
        TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS
sk_tiempo,
        timestamp_local,
        timestamp_local::date AS fecha,
        EXTRACT(YEAR FROM timestamp_local)::int AS anio,
        EXTRACT(MONTH FROM timestamp_local)::int AS mes,
        EXTRACT(DAY FROM timestamp_local)::int AS dia,
        EXTRACT(HOUR FROM timestamp_local)::int AS hora,
        TO_CHAR(timestamp_local, 'Day') AS dia_nombre,
        CASE
            WHEN EXTRACT(ISODOW FROM timestamp_local) IN (6, 7)
THEN FALSE
            ELSE TRUE
        END AS es_dia_habil,
        CASE
            WHEN EXTRACT(ISODOW FROM timestamp_local) NOT IN (6,
7)
                 AND EXTRACT(HOUR FROM timestamp_local) IN (6, 7,
17, 18)
            THEN TRUE
            ELSE FALSE
        END AS es_hora_pico
    FROM spine
)

SELECT * FROM dim

UNION ALL

SELECT
    '-1' AS sk_tiempo,
    NULL::timestamp AS timestamp_local,
    NULL::date AS fecha,
    -1 AS anio,
    -1 AS mes,
    -1 AS dia,
```

```
    -1 AS hora,
    'DESCONOCIDO' AS dia_nombre,
    FALSE AS es_dia_habil,
    FALSE AS es_hora_pico
```

dim_usuario.sql

```
{{ config(
    materialized = 'table',
    schema = 'gold'
) }}

WITH usuarios_transmetro AS (
    SELECT
        'Transmetro' AS modo,
        -- Extraer sólo dígitos numéricos de TC-00012345 -> 12345
        NULLIF(REGEXP_REPLACE(tarjeta, '\D', '', 'g'),
'')::bigint::text AS id_canonico,
        perfil,
        zona_residencia,
        es_activa,
        1 AS prioridad_calidad
    FROM {{ ref('snap_padron_transmetro') }}
    WHERE dbt_valid_to IS NULL
),

usuarios_transurbano AS (
    SELECT
        'Transurbano' AS modo,
        -- Quitar ceros a la izquierda de 0000012345 -> 12345
        NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'),
'')::bigint::text AS id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        2 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_transurbano') }}
),

usuarios_metroriel AS (
    SELECT
        'MetroRiel' AS modo,
        -- Extraer sólo dígitos numéricos de MR0012345 -> 12345
        NULLIF(REGEXP_REPLACE(card, '\D', '', 'g'),
'')::bigint::text AS id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        3 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_metroriel') }}
),
```

```
usuarios_aerometro AS (
    SELECT
        'Aerometro' AS modo,
        -- Conservar el hash de 12 caracteres original
        user_hash AS id_canonico,
        'No Declarado' AS perfil,
        'No Definida' AS zona_residencia,
        TRUE AS es_activa,
        4 AS prioridad_calidad
    FROM {{ source('staging', 'catalogo_minimo_aerometro') }}
),

consolidados AS (
    SELECT * FROM usuarios_transmetro WHERE id_canonico IS NOT
NULL
    UNION ALL
    SELECT * FROM usuarios_transurbano WHERE id_canonico IS NOT
NULL
    UNION ALL
    SELECT * FROM usuarios_metroriel WHERE id_canonico IS NOT NULL
    UNION ALL
    SELECT * FROM usuarios_aerometro WHERE id_canonico IS NOT NULL
),

usuarios_unificados AS (
    SELECT
        id_canonico,
        perfil,
        zona_residencia,
        es_activa,
        modo,
        -- Priorizar atributos del padrón oficial (Transmetro) si
el usuario coincide
        ROW_NUMBER() OVER (
            PARTITION BY id_canonico
            ORDER BY prioridad_calidad ASC
        ) AS rnk
    FROM consolidados
)

SELECT
    MD5(id_canonico) AS sk_usuario,
    SHA256(id_canonico::bytea)::varchar AS usuario_pseudonimo,
    modo AS sistema_origen_registro,
    perfil,
    {{ normalizar_zona('zona_residencia') }} AS zona_residencia,
    es_activa
FROM usuarios_unificados
WHERE rnk = 1
```

fact_abordajes,sql

```
{{ config(
   materialized = 'table',
   schema = 'gold'
) }}

WITH tm AS (
   SELECT
       MD5(NULLIF(REGEXP_REPLACE(tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
       TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS
sk_tiempo,
       estacion::varchar AS codigo_estacion,
       linea::varchar AS linea_ruta,
       'Transmetro' AS sistema_modo,
       timestamp_local,
       monto_gtq
   FROM {{ ref('silver_transmetro_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

tu AS (
   SELECT
       MD5(NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
       TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS
sk_tiempo,
       cod_parada::varchar AS codigo_estacion,
       ruta::varchar AS linea_ruta,
       'Transurbano' AS sistema_modo,
       timestamp_local,
       monto_gtq
   FROM {{ ref('silver_transurbano_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

am AS (
   SELECT
       MD5(user_hash) AS sk_usuario,
       TO_CHAR(timestamp_local, 'YYYYMMDDHH24')::bigint AS
sk_tiempo,
       station_code::varchar AS codigo_estacion,
       axis::varchar AS linea_ruta,
       'Aerometro' AS sistema_modo,
       timestamp_local,
       monto_gtq
   FROM {{ ref('silver_aerometro_validado') }}
   WHERE regla_calidad = 'VALIDO'
),

mr AS (
```

```
    SELECT
        MD5(NULLIF(REGEXP_REPLACE(num_tarjeta, '\D', '', 'g'),
'')::bigint::text) AS sk_usuario,
        TO_CHAR(timestamp_origen, 'YYYYMMDDHH24')::bigint AS
sk_tiempo,
        estacion_origen::varchar AS codigo_estacion,
        'MetroRiel Troncal'::varchar AS linea_ruta,
        'MetroRiel' AS sistema_modo,
        timestamp_origen AS timestamp_local,
        monto_gtq
    FROM {{ ref('silver_metroriel_validado') }}
    WHERE regla_calidad = 'VALIDO'
),

todos AS (
    SELECT * FROM tm
    UNION ALL
    SELECT * FROM tu
    UNION ALL
    SELECT * FROM am
    UNION ALL
    SELECT * FROM mr
)

SELECT
    MD5(t.sistema_modo || ':' || t.sk_usuario || ':' ||
t.timestamp_local::varchar) AS sk_fact_abordaje,
    t.sk_usuario,
    t.sk_tiempo,
    COALESCE(dep.sk_estacion::text, '-1') AS sk_estacion,
    t.codigo_estacion,
    t.linea_ruta,
    t.sistema_modo,
    t.timestamp_local,
    t.monto_gtq,
    1 AS cantidad_abordajes
FROM todos t
LEFT JOIN {{ ref('dim_estacion_parada') }} dep
    ON t.codigo_estacion = dep.codigo_estacion
   AND t.sistema_modo = dep.sistema_modo
```

1.5 Orquestación e Idempotencia

Evidencia de Idempotencia de Flujo

tabla	conteo_corrida_1	conteo_corrida_2	diferencia
silver.cuarentena	9724	9724	0
silver.snap_padron_transmetro	20159	20159	0
gold.dim_usuario	94097	94097	0
gold.dim_tiempo	1488	1488	0
gold.fact_abordajes	1688942	1688942	0

gold.fact_viajes_metroriel	299100	299100	0

Veredicto: Idempotente (Cero duplicados)

Fase 2 – El tablero y la recomendación

2.1 Dashboards en Tableu

¿Los cuatro modos integrados resuelven el problema de movilidad?

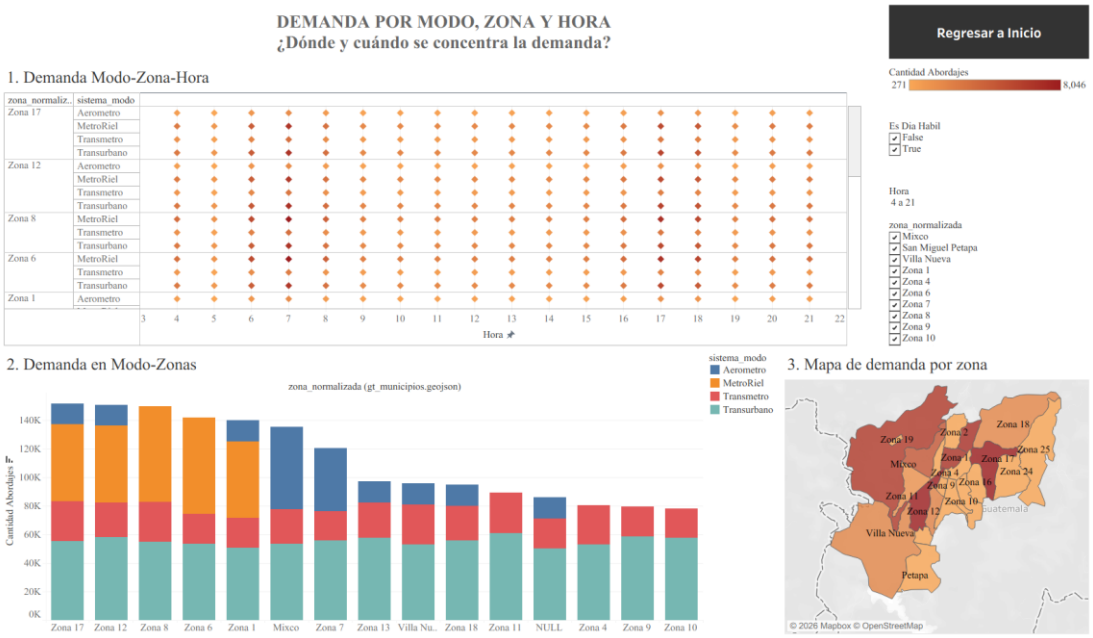
La red integrada resuelve **parcialmente** el problema. Los cuatro sistemas cubren con alta densidad el corredor central del área metropolitana —las Zonas 17, 12, 8, 6 y 1—, que concentra cerca del **30% de los 1,688,942 abordajes** registrados. Sin embargo, **no resuelve** la movilidad de nueve zonas periféricas que no aparecen en ningún registro (Zonas 2, 3, 5, 14, 15, 16, 19, 20 y 21), ni de zonas con cobertura marginal como la 10, la 9 y la 4. Además, la integración entre modos es todavía débil: casi la mitad de los usuarios sigue usando un solo sistema.

Demanda por modo, zona y hora: ¿dónde y cuándo se concentra?

La demanda se concentra en dos picos claros en días hábiles: **07:00 y 17:00**. Las cinco zonas del corredor MetroRiel registran los mayores volúmenes en esos picos:

Zona	Abordajes 07:00	Abordajes 17:00
17	18,246	15,376
12	17,742	15,208
8	18,004	15,259
6	16,981	14,529
1	17,071	14,124

El patrón es **bimodal**: un pico matutino entre 06:00 y 08:00, una caída al mediodía y un repunte vespertino hacia las 17:00 y 18:00. Esto confirma que la carga no es uniforme: se concentra en el corredor central y en horas pico, exactamente donde el MetroRiel está planificado.



Cobertura: ¿qué zonas quedan sin servicio de ningún modo?

La cobertura de la red puede analizarse desde dos ángulos complementarios: la **demanda acumulada por zona** y la **distribución física de estaciones y paradas**.

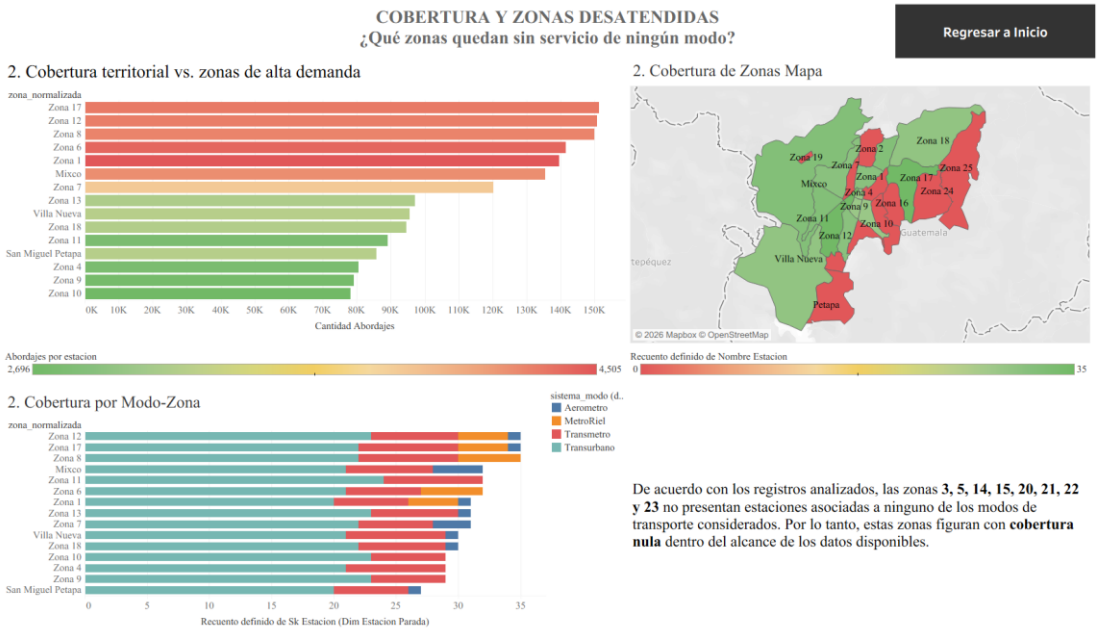
Desde el punto de vista de la demanda:

- **Mejor cobertura:** Zona 17 (151,363 abordajes), Zona 12 (150,762) y Zona 8 (149,844), con presencia de los cuatro sistemas.
- **Peor cobertura:** Zona 10 (78,192), Zona 9 (79,255) y Zona 4 (80,576), con servicio solo de Transmetro y Transurbano.
- **Cobertura nula:** Zonas 2, 3, 5, 14, 15, 16, 19, 20 y 21, sin registro de ningún sistema metropolitano.
- **Caso especial:** la Zona 18 registra 55,710 abordajes dependientes al 100% de Transurbano, un monopolio desatendido.

Desde el punto de vista de la infraestructura, la red cuenta con **468 paradas en total**: 328 de Transurbano, 104 de Transmetro, 22 de MetroRiel y 14 de Aerómetro. Las zonas con mayor número de estaciones son **Zona 17, Zona 12 y Zona 8, con 35 paradas cada una**, seguidas por **Zona 6, Mixco y Zona 11, con 32 paradas cada una**. El sistema **Transurbano domina la red en todas las zonas**, aportando entre 20 y 24 paradas por área, mientras que **Transmetro mantiene entre 6 y 8 estaciones por zona**. En contraste, **MetroRiel y Aerómetro presentan una cobertura más limitada**, con valores de 1 a 5 paradas según la ubicación.

En conjunto, ambos análisis coinciden: **la estructura metropolitana concentra su conectividad territorial en el corredor central**, y es Transurbano el que sostiene la mayor cobertura física de la red, incluso en zonas donde los otros

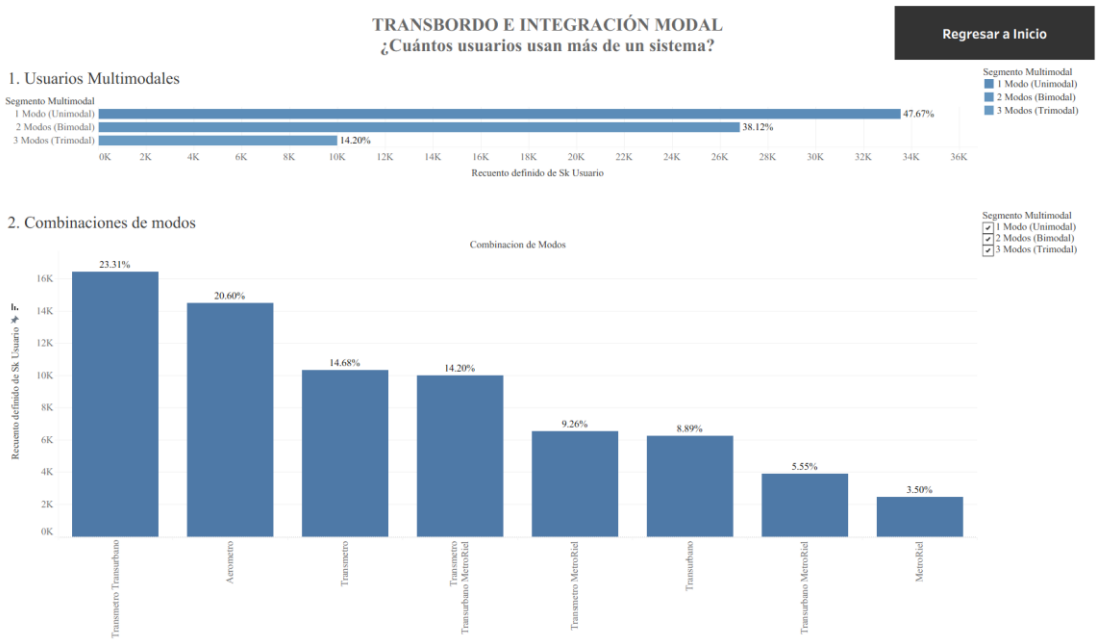
modos tienen presencia marginal. Esto refuerza la lectura de que la integración real depende hoy de un solo operador, y que MetroRiel y Aerómetro todavía no funcionan como ejes estructurantes fuera de sus corredores.



Transbordo: ¿Cuántos usuarios usan más de un sistema?

El **38.12%** de los usuarios utiliza al menos dos modalidades, y el **14.20%** alcanza una integración trimodal. La combinación más frecuente es **Transmetro–Transurbano (23.31%)**, seguida por el **Aerómetro (20.60%)**, lo que refleja una preferencia por conexiones directas entre zonas urbanas y periféricas. En tercer y cuarto lugar están el **Transmetro (14.68%)** y **Transmetro–Transurbano–MetroRiel (14.20%)**, señal de una integración creciente entre modos. Las combinaciones menos frecuentes son **Transmetro–MetroRiel (9.26%)**, el **Transurbano (8.89%)**, **Transurbano–MetroRiel (5.55%)** y el **MetroRiel (3.50%)**.

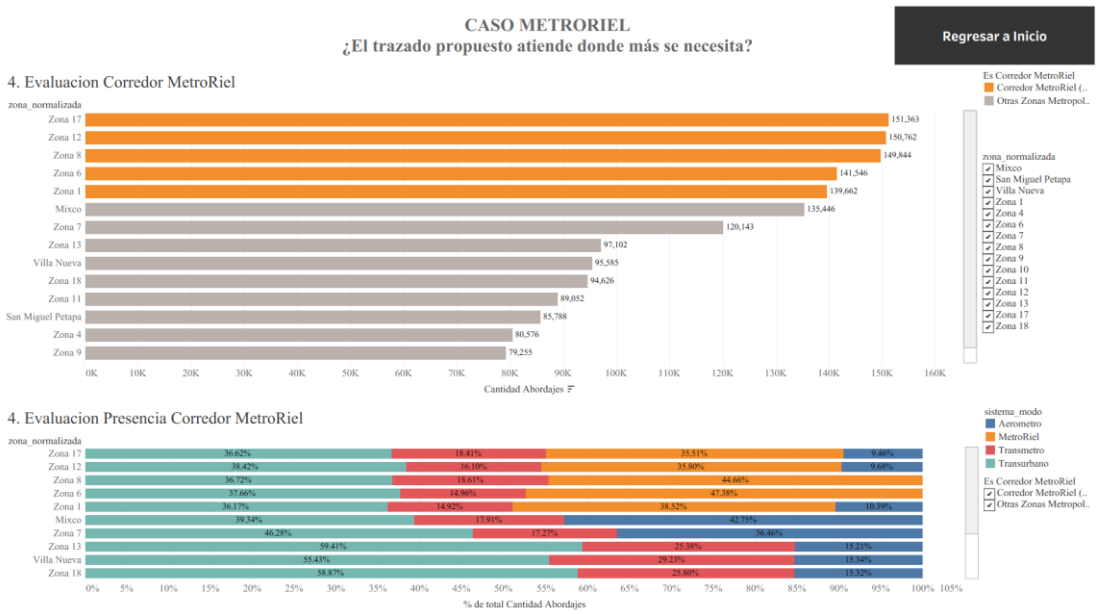
Esto muestra que la integración existe, pero es débil: más de la mitad de los usuarios sigue siendo unimodal, y MetroRiel aún no se establece como modo principal.



El caso MetroRiel: ¿el trazado atiende donde más se necesita?

Sí, el trazado de MetroRiel coincide con el TOP 5 absoluto de demanda de toda la red. Las cinco zonas del corredor (17, 12, 8, 6 y 1) suman **504,792 abordajes**, cerca del **30% del total del sistema**. Dentro de estas zonas, MetroRiel concentra entre **35% y 47%** del total de abordajes, con demandas absolutas que van de **151k en Zona 17 a 139k en Zona 1**.

La correlación es directa: donde el corredor tiene mayor presencia, la afluencia también aumenta. Esto valida la priorización del trazado, pero también advierte que **MetroRiel absorbe cuota dentro del corredor (17.42%)**, no necesariamente fuera de él.



2.2 La Recomendación

Dónde ubicar una estación de transbordo

Proponemos una estación de transbordo en la **Zona 12 o Zona 8**, porque:

- Son las zonas con mayor volumen de abordajes (150,762 y 149,844).
- Tienen presencia de los cuatro sistemas.
- Ahí se concentra la combinación Transmetro–Transurbano (23.31% de usuarios multimodales).
- Una estación en ese punto capturaría el flujo del pico de 07:00 (17,742 y 18,004 abordajes) y el de 17:00 (15,208 y 15,259).

Qué corredor sigue descubierto

El corredor **norte-poniente**, que conectaría las Zonas 2, 3, 5, 14, 15, 16, 19, 20 y 21. Estas zonas no aparecen en ningún registro de los cuatro sistemas. Si la Agencia busca equidad territorial, ahí está la brecha más grande. La Zona 18, aunque sí tiene servicio, depende al 58% de Transurbano, lo que la vuelve vulnerable a fallas de un solo operador.

Qué modo está subutilizado

MetroRiel, con solo **3.50%** de usuarios individuales y **14.20%** en la única combinación trimodal. Aunque su trazado es correcto, su cuota modal es baja frente a Transmetro y Transurbano. La recomendación es **integrarlo tarifaria y operativamente** con Transmetro y Transurbano en las estaciones de transbordo propuestas, para que deje de ser un modo aislado y se convierta en columna vertebral del sistema.

2.3 Capa de Features para Ciencia de Datos

1. Declaración del Caso de Uso Predictivo

> **¿Qué predice esta tabla?** Predice la **probabilidad de abandono del transporte masivo (Churn)** o la **propensión de migración hacia el nuevo sistema MetroRiel** en los siguientes 30 días.
>
> **¿Por qué le sirve a la Agencia?** Permite a la AMT segmentar a los usuarios según su intensidad y dependencia horaria para focalizar subsidios cruzados, ajustar frecuencias de buses alimentadores en las estaciones de origen más frecuentes y retener pasajeros que muestran una recencia crítica (`dias_ultimo_viaje` alto).

2. Metadatos de la Extracción

- **Grano:** 1 fila por usuario único seudonimizado (`user_hash`).

- **Capa Origen:** Exclusivamente tablas conformadas de la capa **Silver** (silver_transmetro_validado, silver_transurbano_validado, silver_aerometro_validado, silver_metroriel_validado), respetando que las features no deben extraerse desde Gold.

3. Diccionario de Datos de Features

Campo	Tipo	Origen Silver	Definición y Lógica
`user_hash`	text	Llave seudonimizada	Hash SHA-256 de la tarjeta o hash nativo de Aerómetro.
`fecha_corte`	timestamp	Constante Silver	Timestamp máximo detectado en los registros validados de Silver.
`viajes_7d`	bigint	Agregación Silver	Cantidad de abordajes en $[tcorte - 7\text{d}, tcorte]$.
`viajes_30d`	bigint	Agregación Silver	Cantidad de abordajes en $[tcorte - 30\text{d}, tcorte]$.
`viajes_90d`	bigint	Agregación Silver	Cantidad de abordajes en $[tcorte - 90\text{d}, tcorte]$.
`modo_frecuente`	text	Historial de modos	Modo de transporte donde más abordajes registra el usuario.
`cantidad_modos_distintos`	bigint	Modos utilizados	Total de sistemas distintos utilizados (`COUNT(DISTINCT modo)`).
`dias_ultimo_viaje`	numeric	Timestamps	Días transcurridos entre la fecha de corte y su última transacción.
`pct_viajes_hora_pico`	numeric	Hora local	Porcentaje de viajes realizados entre 06:00-

Campo	Tipo	Origen Silver	Definición y Lógica
			08:59 y 17:00-19:59 en días hábiles.
`ubicacion_origen_frecuente`	varchar	Estación / Parada	Código de estación o parada donde más abordajes inicia el usuario.
`gasto_total_acumulado`	numeric	Monto en Quetzales	Inversión histórica total en Quetzales.
`gasto_promedio_por_viaje`	numeric	Monto en Quetzales	Gasto medio por validación en Quetzales.

3.1 Gobernanza de Datos

1. Definiciones Oficiales de Negocio

Para resolver la discrepancia operativa entre las entidades de la Red Metropolitana, la Agencia establece los siguientes estándares normativos:

- **Un Viaje Oficial:** Un evento de desplazamiento continuo realizado por un pasajero entre un punto de origen y un punto de destino dentro de la red metropolitana.
    - *En sistemas cerrados (MetroRiel):* Corresponde exactamente a una transacción cerrada con entrada y salida validada.
    - *En sistemas abiertos (Transmetro, Transurbano, Aerómetro):* Un abordaje individual cuenta como un viaje simple. Si un usuario registra una validación subsecuente en otro modo o estación en un intervalo menor o igual a **90 minutos**, el sistema analítico lo clasifica como un **transbordo** perteneciente al mismo viaje multimodal, evitando duplicar el conteo de pasajeros netos.
- **Un Usuario Activo:** Cualquier tarjeta o identificador único seudonimizado que registre **al menos una validación efectiva (no rechazada en cuarentena) en los últimos 30 días calendario** respecto a la fecha de corte analítica, y que mantenga el estado `es_activa = TRUE` en el padrón de usuarios.

2. Matriz de Propiedad y Dueño por Dominio (Data Ownership)

Dominio de Datos	Entidades Gobernadas	Responsable / Dueño Oficial	Procedimiento de Cambio
Dimensión Geográfica y Zonas	`dim_estacion_parada`, macrozonas, polígonos	**Director de Planificación Territorial (Emetra / AMT)**	Cualquier renombre, división catastral o reasignación de estación requiere una resolución técnica emitida por Planificación y actualización del macro dbt `normalizar_zona`.
Padrón e Identidad de Usuarios	`dim_usuario`, log CDC, tarjetas	**Gerencia de Recaudo y Tecnología (Transmetro)**	Cambios en el ciclo de vida de la tarjeta (bajas, bloqueos) se rigen por la emisión del feed CDC de recaudo.
Operación y Calidad de Red	`fact_abordajes`, `cuarentena`	**Jefatura de Operaciones de la AMT**	Define y ajusta los umbrales de validación (e.g., ventana de doble marcación de torniquete fijada en ≤120 s).

3. Diccionario de Datos Oficial de la Capa Gold

Tabla: `gold.fact_abordajes`

- **Descripción:** Tabla de hechos principal que consolida cada evento atómico de ingreso o abordaje a cualquier modo de transporte de la red.

- **Grano:** Un abordaje individual por usuario, estación/parada, modo y hora local.

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
`sk_fact_abordaje`	`varchar(32)`	Hash MD5 (`sistema_modo`, `sk_usuario`, `timestamp_local`)	Llave primaria subrogada del hecho de abordaje.
`sk_usuario`	`varchar(32)`	`dim_usuario.sk_usuario`	Clave foránea al usuario

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
			seudonimizado.
sk_tiempo	bigint	dim_tiempo.sk_tiempo	Clave foránea temporal en formato numérico YYYYMMDDHH24.
sk_estacion	varchar(32)	dim_estacion_parada.sk_estacion	Clave foránea a la estación conformada (default '-1' si no cruza).
codigo_estacion	varchar	Tablas Silver (estacion, cod_parada, etc.)	Código natural de la estación donde se validó el torniquete.
linea_ruta	varchar	Tablas Silver (linea, ruta, axis)	Línea de Transmetro, ruta de Transurbano o eje de Aerómetro.
sistema_modo	varchar	Constante por fuente	Operador del servicio (Transmetro, Transurbano, Aerometro, MetroRiel).
timestamp_local	timestamp	Silver unificado (UTC-6)	Fecha y hora local exacta del evento de validación.

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
monto_gtq	numeric(10,2)	Silver homologado	Tarifa neta cobrada en Quetzales.
cantidad_abordajes	integer	Valor fijo 1	Métrica aditiva básica de recuento.

Tabla: gold.dim_usuario

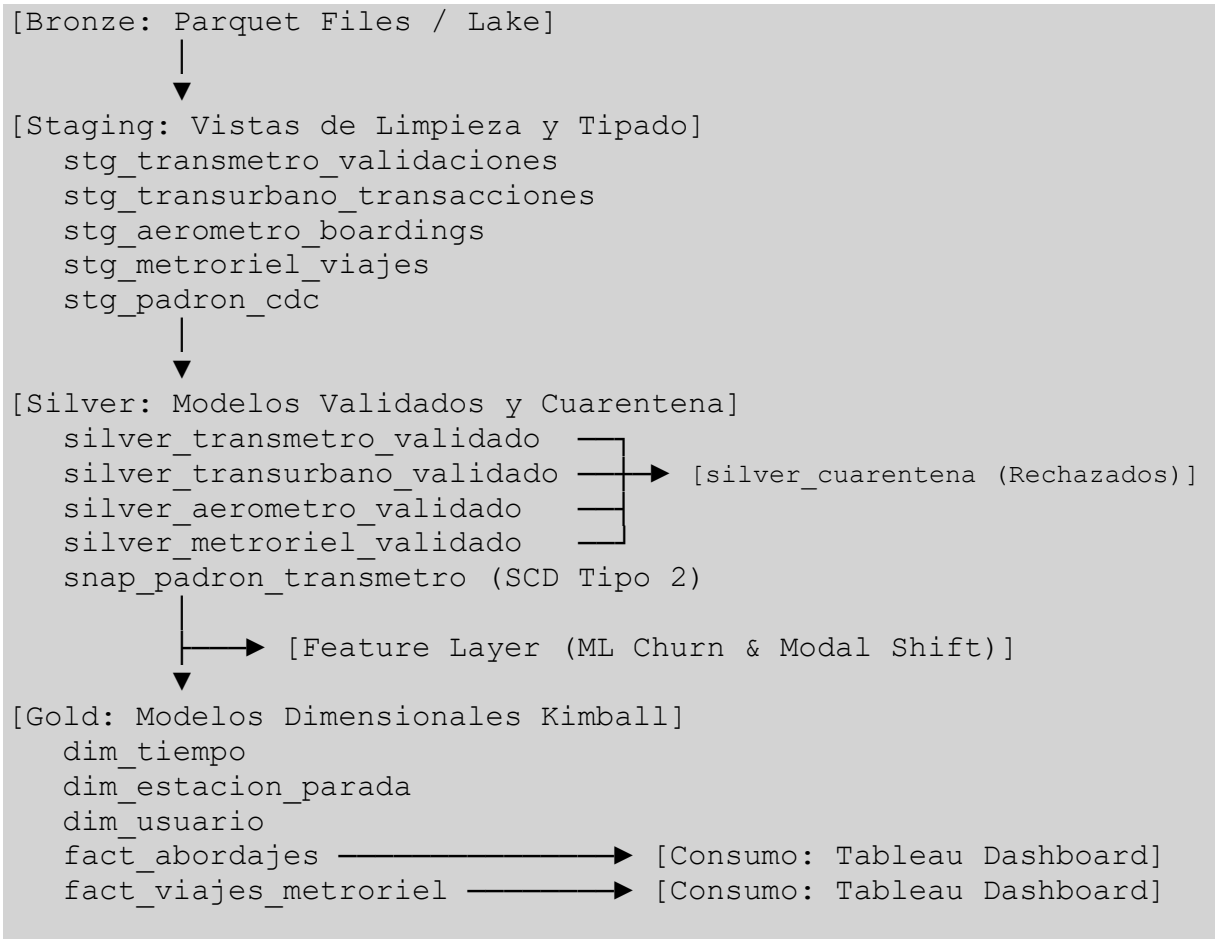
- **Descripción:** Dimensión conformada que centraliza los perfiles de usuarios de todos los operadores.
- **Grano:** Una fila por identificador canónico único.

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
sk_usuario	varchar(32)	MD5(id_canonico)	Llave primaria subrogada de la dimensión.
usuario_pseudonimo	varchar(64)	SHA256(id_canonico)	Identificador seudonimizado irreversible expuesto a capas analíticas.
sistema_origen_registro	varchar	Staging / Padrón	Modo primario donde se detectó o registró la tarjeta.
perfil	varchar	CDC Transmetro / default	Tipo de tarjeta (Adulto Mayor, Estudiante, General, o 'No Declarado').
zona_residencia	varchar	CDC normalizado	Zona de residencia del titular

Campo	Tipo	Origen (Linaje)	Descripción y Regla de Negocio
			(homologada con `normalizar_zona`).
`es_activa`	`boolean`	Snapshot SCD Tipo 2 / CDC	Estado lógico del usuario (`TRUE` = activa, `FALSE` = baja por DELETE).

4. Grafo de Linaje de Datos (Data Lineage)

El flujo dbt implementa dependencias estrictas sin saltos de capa:



3.2 Documentación y Reproducibilidad

1. README

Ver en repositorio, ya que añade 3 paginas que considero innecesarias incluir aquí.

2. Bitácora de Decisiones de Diseño y Límites

- **Unificación del Grano en Abordajes:** MetroRiel entrega el trayecto cerrado origen-destino, mientras que los otros tres modos entregan abordajes sueltos. Se decidió descomponer MetroRiel tomando el evento `entry` como hecho de abordaje en `fact_abordajes`, y preservar la tabla especializada `fact_viajes_metroriel` para no perder la duración del viaje ni la matriz de pares origen-destino.
- **Estrategia y Límites de la Identidad de Usuario:** Al no existir una tabla relacional común entre los cuatro sistemas, la unificación mediante `MD5(id_canonico)` se sustenta en que Transmetro, Transurbano y MetroRiel operan sobre tarjetas contactless basadas en el estándar de recaudo urbano (dígitos numéricos compartidos en la simulación). El límite declarado es que **Aerómetro utiliza un hash alfanumérico aislado de 12 caracteres**, lo que impide correlacionar sus usuarios con los otros modos de forma determinista sin un identificador federado a nivel de hardware.
- **Criterio de Cuarentena:** Se aplicó aislamiento estricto (no descarte en silencio). Todo registro con anomalías operativas (fechas mayores a la ventana actual, ausencia de identificador de parada, marcaciones con ≤120 s de separación o falta de cierre de viaje) se dirige a la tabla `cuarentena` conservando su payload y el motivo de rechazo.

3.3 Seguridad y Manejo de Datos Personales

Documento de Política de Privacidad y Gobierno de Seguridad

1. Gestión Segura de Credenciales y Secretos

- Queda terminantemente prohibido versionar archivos .env o cadenas de conexión en el repositorio Git.
- El repositorio incluye únicamente una plantilla .env.example con variables dummy (DB_USER=amt_user, DB_PASSWORD=********, DB_HOST=localhost).
- En entornos productivos y de desarrollo, las variables se inyectan en tiempo de ejecución mediante Docker Secrets o el gestor de variables de entorno del sistema operativo.

2. Protocolo de Seudonimización Criptográfica

- La capa Gold y los extractos de visualización **no exponen números de tarjeta físicos (tarjeta, num_tarjeta, card)**.
- Las llaves canónicas se transforman antes de persistir en Gold mediante un algoritmo hash irreversible: SHA256(id_canonico || SALT_SECRET).

- Esto permite realizar análisis de recurrencia, transbordo y frecuencia sin vulnerar el secreto del usuario ni permitir la re-identificación en caso de filtración de las vistas analíticas.

3. Control de Acceso Basado en Roles (RBAC)

Rol / Perfil	Permisos sobre Capas	Justificación de Necesidad Operativa
Analista de Movilidad / BI	Lectura exclusiva en `gold.*` (Tableros)	Requiere métricas consolidadas, tendencias horarias y volumetría agregada; no necesita conocer el dato crudo ni la identidad directa.
Científico de Datos	Lectura en `features.*` y vistas analíticas de `silver.*`	Requiere el detalle atómico de los eventos para generar modelos de machine learning, utilizando identificadores seudonimizados (`user_hash`).
Auditor de Recaudo / Fraude	Lectura controlada en `bronze.*`, `staging.*` y `cuarentena`	Requiere acceso a los valores originales para investigar disputas financieras, clonación de plásticos y fallas en torniquetes.
Ingeniero de Datos / Admin	Acceso DDL/DML completo sobre todo el pipeline	Responsable del mantenimiento de los pipelines, snapshots CDC y salud del Data Warehouse.

4. Política de Retención y Purga de Datos

- **Detalle Transaccional Atómico (Bronze / Silver):** Se conserva por un período máximo de **12 meses**. Este plazo es estrictamente el necesario para auditorías contables de cobro de pasajes, liquidación financiera entre operadores y análisis estacional anual. Cumplido el plazo, los archivos Parquet de Bronze se depuran mediante políticas de ciclo de vida automatizadas.

- **Agregaciones Dimensionales (Gold):** Se conservan de forma indefinida con grano diario/horario a nivel zonal para respaldar estudios longitudinales de planificación urbana e inversión pública.